

Social Link Analysis and Prediction

January 20, 2026

Báo cáo đồ án: PYTHON CHO KHOA HỌC DỮ LIỆU

Lớp 23TTH. Khoa Toán - Tin học

Đề tài: Social Link Analysis and Prediction

Giảng viên bộ môn: ThS. Hà Văn Thảo

Thành viên nhóm:

- 23110202 - Nguyễn Quốc Anh Quân
- 23110203 - Nguyễn Minh Quang
- 23110206 - Đinh Nhật Tân

Github: <https://github.com/minhquang0407/Social-Link-Prediction>

Dataset: <https://drive.google.com/drive/u/0/folders/1SsVRhTo9tulcpszo-9Uv4NDkKTR7mN3u>

1 GIỚI THIỆU

1.1 Thành viên nhóm

1.2 Bối cảnh dự án

– Trong kỷ nguyên tri thức số, các **Đồ thị Tri thức (Knowledge Graphs - KG)** như Wikidata đóng vai trò là “xương sống” cho các hệ thống Trí tuệ nhân tạo hiện đại. Tuy nhiên, một thách thức lớn mà các hệ thống này đang đối mặt chính là “**Vùng tối tri thức**” – nơi các mối quan hệ xã hội thực tế tồn tại nhưng chưa được số hóa, dẫn đến tính không đầy đủ và thừa thớt của dữ liệu.

– Nếu các thuật toán đồ thị truyền thống mạnh về **suy luận tường minh (Explicit Reasoning)** dựa trên cấu trúc topo nhưng lại hạn chế trong việc dự báo, thì mạng Nơ-ron đồ thị lại có thể mạnh vượt trội trong việc **khai phá tiềm ẩn (Implicit Learning)**. Đề tài này được xây dựng trên nền tảng kiến trúc Neuro-Symbolic AI, một hướng tiếp cận lai nhằm tối ưu hóa sự kết hợp giữa: * **Symbolic**: Khả năng suy luận logic chặt chẽ của lý thuyết đồ thị. * **Neural**: Khả năng học biểu diễn mạnh mẽ của Deep Learning trên không gian vector liên tục.

1.3 Mục tiêu dự án

Dự án hướng tới việc thực hiện bốn nhiệm vụ trọng tâm mang tính chiến lược:

- **Kiến tạo Đồ thị Tri thức Dị thể**: Thu thập, chuẩn hóa và cấu trúc hóa dữ liệu từ Wikidata

để xây dựng mạng lưới thực thể đa tầng, kết nối thực thể con người với các thực thể giáo dục, chính trị và nghệ thuật.

– **Kiểm chứng Giả thuyết Toán học:** Sử dụng các thuật toán đường đi (*Shortest Path*) để định lượng “khoảng cách xã hội”, thực nghiệm hóa lý thuyết **Six Degrees of Separation** (Sáu bậc phân cách) trên quy mô dữ liệu thực tế.

– **Phân tích Cấu trúc & Cộng đồng:** Áp dụng các kỹ thuật phân tích mạng lưới xã hội (SNA) để định vị các thực thể lõi (**Hubs**) và nhận diện các cấu trúc cộng đồng ẩn (**Community Detection**).

– **Dự báo liên kết tiên tiến (Link Prediction):** Phát triển mô hình mạng Nơ-ron đồ thị (GNN) để dự báo xác suất hình thành các mối quan hệ tiềm ẩn, mở ra ứng dụng trong các hệ thống gợi ý và phân tích hành vi xã hội.

1.4 Nguồn tài nguyên dữ liệu

Nguồn dữ liệu: Wikidata (Knowledge Graph mở lớn nhất thế giới).

Đặc điểm: Dữ liệu có cấu trúc (Structured Data), được cộng đồng kiểm duyệt chặt chẽ, đảm bảo tính khách quan và độ tin cậy cao hơn so với dữ liệu cào web (raw text crawling).

Dự án khai thác trực tiếp tài nguyên từ **Wikidata Endpoint** thông qua ngôn ngữ truy vấn **SPARQL**. Đây là nguồn dữ liệu mở, đa ngôn ngữ và có cấu trúc chặt chẽ (Ontology), cho phép trích xuất các bộ ba tri thức (Knowledge Triples) theo định dạng:

$$T = (S, P, O)$$

Trong đó: * *S* (Subject): Thực thể nguồn. * *P* (Predicate): Quan hệ/Thuộc tính kết nối. * *O* (Object): Thực thể đích hoặc giá trị thuộc tính.

2 LÝ THUYẾT CƠ SỞ

2.1 Tổng quan và Mô hình hóa Đồ thị Tri thức

Để hiện thực hóa bài toán phân tích mạng lưới xã hội phức hợp, dự án này sử dụng cấu trúc **Đồ thị Dị thể (Heterogeneous Graph)**. Đây là nền tảng cho phép chúng ta không chỉ biểu diễn mối quan hệ giữa người với người, mà còn tích hợp các thực thể trung gian như tổ chức, trường học và sự kiện.

2.1.1 Khái niệm và Định nghĩa toán học

- Đồ thị quan hệ (Relational Graph):** Là mô hình toán học $G = (V, E)$ đại diện cho các thực thể và sự kết nối.
 - Tập đỉnh (V):** Các thực thể (Nodes) mang đặc trưng ngữ nghĩa.
 - Tập cạnh (E):** Mối quan hệ (Edges) tồn tại khi có sự tương tác giữa hai thực thể.
- Đồ thị dị thể (Heterogeneous Graph):** Khác với đồ thị đồng nhất, đồ thị dị thể cho phép tồn tại đa loại đỉnh và đa loại cạnh: $G = (V, E, \mathcal{A}, \mathcal{R})$
 - Tập hợp các loại nút ($\mathcal{A}$):** Human, Organization, Film, WrittenWork...
 - Tập hợp các loại quan hệ ($\mathcal{R}$):** work_at, spouse, authored, acted_in...

- **Ánh xạ**

$$\phi : V \rightarrow \mathcal{A}$$

và

$$\psi : E \rightarrow \mathcal{R}$$

Điều này giúp mô hình hóa thế giới thực một cách chính xác hơn, nơi các thực thể có bản chất khác nhau tương tác qua các giao thức khác nhau.

2.1.2 Định nghĩa Bậc trung gian (Social Distance)

Trong dự án này, chúng ta xác định khoảng cách xã hội dựa trên giả thuyết “**Sáu bậc phân cách**”. Tuy nhiên, để tập trung vào bản chất xã hội, chúng ta định nghĩa **Bậc trung gian** chỉ tính trên các thực thể thuộc loại **Người (Person)**.

- **Logic tính toán:** Số bậc được tính bằng số lượng nút loại **Human** xuất hiện trên đường đi giữa hai đối tượng, đóng vai trò là cầu nối.
- **Ví dụ:** Xét lộ trình liên kết: $A \rightarrow \text{HCMUS} \rightarrow B \rightarrow C$.
 - Mặc dù có 3 cạnh nối, nhưng khoảng cách xã hội ở đây là **2 bậc** (thông qua thực thể B và C).

2.1.3 Cấu trúc dữ liệu và Thư viện triển khai

Dự án sử dụng thư viện **igraph** để lưu trữ và phân tích. **igraph** được tối ưu hóa bằng ngôn ngữ C, cho phép xử lý các phép tính đồ thị phức tạp với hiệu suất vượt trội so với các thư viện thuần Python.

Chiến lược Đánh chỉ mục (Indexing Strategy) Vì **igraph** quản lý các đỉnh dựa trên số nguyên (Integer IDs), chúng ta sử dụng cơ chế **Mapping** trực tiếp: * Sử dụng **index** của **DataFrame nodes** làm định danh nội bộ cho **igraph**. * Thiết lập một bảng tra cứu để chuyển đổi giữa **Wikidata ID** và **Internal Index**.

2.1.4 Thuộc tính thực thể (Attributes)

Thành phần	Thuộc tính	Ý nghĩa
Đỉnh (Vertex)	id	Mã định danh duy nhất từ Wikidata (Q-ID).
	name	Tên hiển thị của thực thể.
	description	Mô tả ngắn gọn về vai trò/ngữ nghĩa.
	birthYear	Dữ liệu thời gian phục vụ phân tích xu hướng thế hệ.
Cạnh (Edge)	relationshipLabel	Nhãn của mối quan hệ (ví dụ: <i>employer</i> , <i>alumni</i>).

3 QUY TRÌNH THU THẬP DỮ LIỆU

Dữ liệu sẽ được thu thập theo quy trình **ETL**:

$$\text{Extractor} \longrightarrow \text{Transformer} \longrightarrow \text{Loader}$$

Cụ thể:

$$\text{Source} \xrightarrow{\text{Extractor}} \text{Raw Data} \xrightarrow{\text{Transformer}} \text{Cleaned Data} \xrightarrow{\text{LOADER}} \text{Done}$$

Trong dự án này, ta sẽ dùng **Multi-stage ETL**, nghĩa là ETL đa giai đoạn:

$$\text{Wikidata} \xrightarrow{\text{Extractor}} \text{Raw Edges Data} \xrightarrow{\text{Transformer}} \text{Cleaned Edges Data} \xrightarrow{\text{Extractor}} \text{Raw Nodes Data} \xrightarrow{\text{Transformer}} \text{Cleaned Nodes Data}$$

3.1 Extractor

Đây là giai đoạn **THU THẬP** và **TRÍCH XUẤT** dữ liệu thô, chưa được làm sạch.

SPARQL: NGÔN NGỮ TRUY VẤN MẠNG LƯỚI TRI THỨC

Khái niệm cơ bản **SPARQL** (*SPARQL Protocol and RDF Query Language*) là ngôn ngữ truy vấn tiêu chuẩn dành cho dữ liệu đồ thị RDF.

So sánh: * **SQL**: Làm việc với các **Bảng** (Hàng & Cột) - Giống như tìm dữ liệu trong bảng Excel. * **SPARQL**: Làm việc với các **Mạng lưới** (Nút & Cạnh) - Giống như tìm kiếm các mối liên kết trong não bộ hoặc mạng xã hội.

Nguyên lý Bộ Ba (The RDF Triple) Mọi tri thức trên thế giới, dù phức tạp đến đâu, đều được SPARQL phân tách thành các đơn vị nhỏ nhất gọi là **Bộ ba (Triple)**.

Công thức toán học:

$$T = (S, P, O)$$

Trong đó: * **S (Subject - Chủ thể)**: Đối tượng chính cần mô tả (Đỉnh bắt đầu). * **P (Predicate - Thuộc tính)**: Mối quan hệ hoặc đặc điểm (Cạnh nối). * **O (Object - Đối tượng)**: Giá trị cụ thể hoặc một thực thể khác (Đỉnh kết thúc).

Ví dụ thực tế: Để tìm “Nơi sinh của Leonardo”, ta đặt một câu hỏi có biến số $?x$

$$\text{Leonardo da Vinci} \xrightarrow{\text{nơi sinh}} (?x)$$

Cơ chế hoạt động: Khớp mẫu đồ thị (Graph Matching) Thay vì quét qua các hàng, SPARQL đi tìm những “mảnh ghép còn thiếu” để hoàn thiện một sơ đồ.

- **Bước 1:** Ta đưa ra một mẫu đồ thị có chứa biến số (ký hiệu bằng dấu ?).
- **Bước 2:** Hệ thống so khớp mẫu này với kho dữ liệu khổng lồ của Wikidata.
- **Bước 3:** Trả về tất cả các giá trị có thể lấp đầy vào vị trí của biến số đó.

Mô hình toán học: Hệ thống tìm tập hợp kết quả $\mathcal{R}$ sao cho:

$$\mathcal{R} = \{?x \mid \text{Mẫu}(?x) \subseteq \text{Đồ thị Wikidata}\}$$

Cấu trúc một truy vấn cơ bản

Thành phần	Chức năng	Ý nghĩa kỹ thuật
SELECT	Chọn dữ liệu	Phép chiếu (Projection) xác định biến đầu ra.
WHERE	Điều kiện khớp	Định nghĩa cấu trúc bộ ba $T = (S, P, O)$ cần tìm.
?variable	Biến số	Đại diện cho thông tin chưa biết (X).
Dấu chấm .	Kết nối	Tương đương phép hội ($\wedge$) trong logic học.

Giải thích các hàm dùng trong truy vấn

- **SELECT ?item:** Xác định biến ?item sẽ được xuất ra bằng kết quả.
- **wdt:P31:** Một thuộc tính cụ thể (ví dụ: “là một của”).
- **wd:Q5:** Một thực thể cụ thể (ví dụ: “con người”).
- **Cách dùng:** Ta kết hợp chúng thành một câu lệnh hoàn chỉnh: `?person wdt:P31 wd:Q5 .` (Tìm tất cả thực thể là con người).

Ta sẽ dùng ngôn ngữ này để truy vấn hai bộ dữ liệu **EDGES** và **NODES**

Ta sẽ chạy thử 1 đoạn truy vấn lấy dữ liệu **EDGES**

Truy cập trang web: <https://query.wikidata.org/>

Chạy thử truy vấn 10 cặp vợ chồng:

```
SELECT  ?person ?personLabel
        ?object ?objectLabel
        ?relationshipLabel
WHERE {
    ?person wdt:P26 ?object.
    BIND("spouse" AS ?relationshipLabel)
    SERVICE wikibase:label {
```

```

        bd:serviceParam wikibase:language "en,vi".
    }
}
LIMIT 10

```

Trong đó:

wdt:P26 là **thuộc tính** vợ chồng

Label để lấy **nhân tên** của biến đó

BIND để gán **một chuỗi** hoặc **1 giá trị** cụ thể cho 1 biến.

Tiếp theo chúng ta sẽ lấy truy vấn về máy.

Ta sử dụng thư viện SPARQLWrapper, đây là 1 đối tượng trung gian thực hiện gửi truy vấn đến Wikidata và trả về, ta sẽ thử với truy vấn 10 cặp vợ chồng ở trên.

```
[1]: from SPARQLWrapper import SPARQLWrapper, JSON
```

```
[2]: query = """
SELECT ?person ?personLabel
      ?object ?objectLabel
      ?relationshipLabel
WHERE {

    ?person wdt:P26 ?object.
    BIND("spouse" AS ?relationshipLabel)

    SERVICE wikibase:label {
        bd:serviceParam wikibase:language "en,vi".
    }
}
LIMIT 5
"""

```

Khởi tạo đối tượng trung gian để lấy truy vấn Wikidata.

```
[3]: endpoint = "https://query.wikidata.org/sparql" #Endpoint of Wikidata
sparql = SPARQLWrapper(endpoint)
sparql.setReturnFormat(JSON) #return json structure
sparql.setQuery(query)

```

Bắt đầu truy vấn.

```
[4]: response = sparql.query().convert() #Decode raw data
result = response["results"]["bindings"]
result

```

```
[4]: [{'relationshipLabel': {'type': 'literal', 'value': 'spouse'},
      'person': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q191789'},
      'object': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q23'},
      'personLabel': {'xml:lang': 'en',
                      'type': 'literal',

```

```

    'value': 'Martha Washington'},
    'objectLabel': {'xml:lang': 'en',
    'type': 'literal',
    'value': 'George Washington'}}},
{'relationshipLabel': {'type': 'literal', 'value': 'spouse'},
 'person': {'type': 'uri',
 'value': 'http://www.wikidata.org/entity/Q1095612'},
 'object': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q24'},
 'personLabel': {'xml:lang': 'en', 'type': 'literal', 'value': 'Teri Bauer'},
 'objectLabel': {'xml:lang': 'en', 'type': 'literal', 'value': 'Jack Bauer'}},
{'relationshipLabel': {'type': 'literal', 'value': 'spouse'},
 'person': {'type': 'uri',
 'value': 'http://www.wikidata.org/entity/Q14623681'},
 'object': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q42'},
 'personLabel': {'xml:lang': 'en', 'type': 'literal', 'value': 'Jane Belson'},
 'objectLabel': {'xml:lang': 'en',
 'type': 'literal',
 'value': 'Douglas Adams'}}},
{'relationshipLabel': {'type': 'literal', 'value': 'spouse'},
 'person': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q13133'},
 'object': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q76'},
 'personLabel': {'xml:lang': 'en',
 'type': 'literal',
 'value': 'Michelle Obama'},
 'objectLabel': {'xml:lang': 'en',
 'type': 'literal',
 'value': 'Barack Obama'}}},
{'relationshipLabel': {'type': 'literal', 'value': 'spouse'},
 'person': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q215062'},
 'object': {'type': 'uri', 'value': 'http://www.wikidata.org/entity/Q91'},
 'personLabel': {'xml:lang': 'en',
 'type': 'literal',
 'value': 'Mary Todd Lincoln'},
 'objectLabel': {'xml:lang': 'en',
 'type': 'literal',
 'value': 'Abraham Lincoln'}}}]

```

Trở về 1 cấu trúc JSON rất phức tạp, 1 **list of dict of dict**, do đó ta qua bước **Transformer**.

3.2 Transformer

Giai đoạn chuyển đổi từ dữ liệu **thô** sang dữ liệu **sạch**, được chuẩn hóa, làm sạch và tăng cường.

Ta sẽ dùng hàm `json_normalize` của thư viện `pandas` để làm phẳng cấu trúc JSON này, hàm sẽ chuyển cấu trúc **list of dict of dict** thành 1 dataframe

```
[5]: import pandas as pd
```

```
[6]: edges = pd.json_normalize(result)
edges.head()
```

```
[6]: relationshipLabel.type relationshipLabel.value person.type \
0          literal          spouse          uri
1          literal          spouse          uri
2          literal          spouse          uri
3          literal          spouse          uri
4          literal          spouse          uri

          person.value object.type \
0  http://www.wikidata.org/entity/Q191789          uri
1  http://www.wikidata.org/entity/Q1095612          uri
2  http://www.wikidata.org/entity/Q14623681          uri
3  http://www.wikidata.org/entity/Q13133          uri
4  http://www.wikidata.org/entity/Q215062          uri

          object.value personLabel.xml:lang personLabel.type \
0  http://www.wikidata.org/entity/Q23          en          literal
1  http://www.wikidata.org/entity/Q24          en          literal
2  http://www.wikidata.org/entity/Q42          en          literal
3  http://www.wikidata.org/entity/Q76          en          literal
4  http://www.wikidata.org/entity/Q91          en          literal

          personLabel.value objectLabel.xml:lang objectLabel.type objectLabel.value
0  Martha Washington          en          literal  George Washington
1          Teri Bauer          en          literal          Jack Bauer
2          Jane Belson          en          literal          Douglas Adams
3  Michelle Obama          en          literal          Barack Obama
4  Mary Todd Lincoln          en          literal  Abraham Lincoln
```

Ta thấy, ở đây có các cột dư thừa rất nhiều, các cột cần thiết có đuôi `.value` theo sau, do đó ta sẽ tiến hành lọc đồng thời bỏ đi đuôi `.value`

```
[7]: valid_columns = {col: col.replace('.value','') for col in edges.columns if col.
    ↪endswith('.value')}
edges = edges[valid_columns.keys()]
edges = edges.rename(columns = valid_columns)
edges.head()
```

```
[7]: relationshipLabel          person \
0          spouse  http://www.wikidata.org/entity/Q191789
1          spouse  http://www.wikidata.org/entity/Q1095612
2          spouse  http://www.wikidata.org/entity/Q14623681
3          spouse  http://www.wikidata.org/entity/Q13133
4          spouse  http://www.wikidata.org/entity/Q215062

          object          personLabel          objectLabel
```



```

0 http://www.wikidata.org/entity/Q23 Martha Washington George Washington
1 http://www.wikidata.org/entity/Q24 Teri Bauer Jack Bauer
2 http://www.wikidata.org/entity/Q42 Jane Belson Douglas Adams
3 http://www.wikidata.org/entity/Q76 Michelle Obama Barack Obama
4 http://www.wikidata.org/entity/Q91 Mary Todd Lincoln Abraham Lincoln

```

Giờ ta sẽ chuẩn hóa lại id, cột person và object. Sau đó cập nhật 2 cột là personType và objectType

```

[9]: edges['person'] = edges['person'].astype(str).str.split('/').str[-1]
edges['object'] = edges['object'].astype(str).str.split('/').str[-1]
edges.head()

```

```

[9]: relationshipLabel  person object  personLabel  objectLabel
0 spouse Q191789 Q23 Martha Washington George Washington
1 spouse Q1095612 Q24 Teri Bauer Jack Bauer
2 spouse Q14623681 Q42 Jane Belson Douglas Adams
3 spouse Q13133 Q76 Michelle Obama Barack Obama
4 spouse Q215062 Q91 Mary Todd Lincoln Abraham Lincoln

```

Tiếp theo, ta thực hiện lọc ID và NAME:

– NAME chuẩn: Không được bắt đầu bằng Q và theo sau là số. – ID chuẩn: Phải bắt đầu bằng Q và theo sau là số.

1 Dòng được giữ lại nếu ID của cả person và object đều thỏa mãn. Ta sẽ dùng `all()`.

1 Dòng bị loại bỏ nếu NAME của 1 trong hai person và object không thỏa mãn. Ta sẽ dùng `any()`

Tất cả đều áp dụng lên `axis = 1`

```

[10]: regex = r'^Q\d+$'
col_id = ['person', 'object']
col_name = ['personLabel', 'objectLabel']

mask_id = edges[col_id].stack().str.match(regex, na=False).unstack().all(axis=1)

mask_name = edges[col_name].stack().str.match(regex, na=False).unstack().
    ↪ any(axis=1)

edges = edges[mask_id | ~mask_name]
edges

```

```

[10]: relationshipLabel  person object  personLabel  objectLabel
0 spouse Q191789 Q23 Martha Washington George Washington
1 spouse Q1095612 Q24 Teri Bauer Jack Bauer
2 spouse Q14623681 Q42 Jane Belson Douglas Adams
3 spouse Q13133 Q76 Michelle Obama Barack Obama
4 spouse Q215062 Q91 Mary Todd Lincoln Abraham Lincoln

```

Tiếp theo, ta sẽ lọc bỏ các cạnh dư thừa, dùng `drop_duplicates()`

```
[11]: edges = edges.drop_duplicates(subset = None, keep = 'first')
```

Theo như lúc đầu, đây sẽ là 1 đồ thị vô hướng, do đó không được tồn tại cạnh ngược.

Ta sẽ tiến hành lọc các cạnh ngược dựa vào **id** và **relationship**

Logic:

- Tạo 1 cột mới với nếu thực thể có **id** nhỏ hơn thì đứng trước, cách nhau dấu gạch dưới và relationship đứng cuối, như sau:

id1_id2_rel

- Cuối cùng ta sẽ lọc dòng lặp dựa trên cột mới tạo.

```
[12]: import numpy as np
p1 = edges['person'].values
p2 = edges['object'].values
rel = edges['relationshipLabel'].values

node_min = np.where(p1 < p2, p1, p2)
node_max = np.where(p1 < p2, p2, p1)

edges_keys = pd.Series(node_min).astype(str) + "_" + \
              pd.Series(node_max).astype(str) + "_" + \
              pd.Series(rel).astype(str)

edges['key'] = edges_keys
edges.head()
```

```
[12]: relationshipLabel  person object  personLabel  objectLabel \
0      spouse      Q191789  Q23  Martha Washington  George Washington
1      spouse      Q1095612  Q24      Teri Bauer      Jack Bauer
2      spouse      Q14623681  Q42      Jane Belson      Douglas Adams
3      spouse      Q13133  Q76      Michelle Obama      Barack Obama
4      spouse      Q215062  Q91  Mary Todd Lincoln      Abraham Lincoln

      key
0  Q191789_Q23_spouse
1  Q1095612_Q24_spouse
2  Q14623681_Q42_spouse
3  Q13133_Q76_spouse
4  Q215062_Q91_spouse
```

```
[14]: edges = edges.drop_duplicates('key', keep = 'first')
edges.head()
```

```
[14]: relationshipLabel  person object  personLabel  objectLabel \
0      spouse      Q191789  Q23  Martha Washington  George Washington
1      spouse      Q1095612  Q24      Teri Bauer      Jack Bauer
2      spouse      Q14623681  Q42      Jane Belson      Douglas Adams
3      spouse      Q13133  Q76      Michelle Obama      Barack Obama
4      spouse      Q215062  Q91  Mary Todd Lincoln      Abraham Lincoln
```

	key
0	Q191789_Q23_spouse
1	Q1095612_Q24_spouse
2	Q14623681_Q42_spouse
3	Q13133_Q76_spouse
4	Q215062_Q91_spouse

Tiếp theo, ta sẽ thực hiện **Extractor** lần 2 để lấy bộ dữ liệu **NODES** từ các **id** bộ dữ liệu **EDGES** này.

– Ta sẽ lấy thứ 3 thuộc tính để demo và **Name**, **Description** và **Birh Year**.

Ta sẽ tạo 1 list id tổng hợp từ person và object. Do ID có thể trùng nên ta sẽ dùng `drop_duplicates`.

```
[91]: per = edges['person']
      obj = edges['object']
      ids = pd.concat([per, obj], ignore_index = True).drop_duplicates()
      ids.head()
```

```
[91]: 0      Q191789
      1      Q1095612
      2      Q14623681
      3      Q13133
      4      Q215062
      dtype: object
```

Thiết lập **query**.

```
[106]: query = """
SELECT ?id ?idLabel ?idDescription ?birthYear
WHERE {
    VALUES ?id {##ids##}
    ?id wdt:P569 ?dob.
    BIND(YEAR(?dob) AS ?birthYear)
    SERVICE wikibase:label {
        bd:serviceParam wikibase:language "en,vi".
    }
}
"""
```

VALUES thực hiện gán cho biến `?id` bằng các giá trị nằm trong `{}`.

– Yêu cầu là dãy id phải bắt đầu bằng `wd:` và cách nhau bởi khoảng trắng

– Ta thực hiện lấy list id của nodes.

```
[92]: ids = " ".join("wd:" + ids)
      ids
```

```
[92]: 'wd:Q191789 wd:Q1095612 wd:Q14623681 wd:Q13133 wd:Q215062 wd:Q23 wd:Q24 wd:Q42
      wd:Q76 wd:Q91'
```

Tiếp theo, ta sẽ thực hiện thay thế `##ids##` trong query bằng chuỗi này và truy vấn.

```
[113]: query = query.replace('##ids##', ids)
sparql.setQuery(query)
response = sparql.query().convert() #Decode raw data
result = response["results"]["bindings"]
```

Ta lại thực hiện **Transformer** lần 2 cho bộ dữ liệu này.

```
[112]: nodes = pd.json_normalize(result)
valid_columns = {col: col.replace('.value', '') for col in nodes.columns if col.
    ↪endswith('.value')}
nodes = nodes[valid_columns.keys()]
nodes = nodes.rename(columns = valid_columns)
nodes['id'] = nodes['id'].astype(str).str.split('/').str[-1]
nodes = nodes.rename(columns = {
    'id': 'id',
    'idLabel': 'name',
    'idDescription': 'description',
    'subtypeLabel': 'subtype',
})
nodes.head()
```

```
[112]:
```

	id	idLabel	idDescription \
0	Q23	George Washington	Founding Father and first U.S. president (1789...
1	Q24	Jack Bauer	character from the television series 24
2	Q42	Douglas Adams	British science fiction writer and humorist (1...
3	Q76	Barack Obama	president of the United States from 2009 to 2017
4	Q91	Abraham Lincoln	President of the United States from 1861 to 18...

	birthYear
0	1732
1	1966
2	1952
3	1961
4	1809

Cuối cùng, ta có 2 bộ dữ liệu sạch, như sau:

- **edges**: sẽ là bộ dữ liệu chứa các cạnh nối giữa 2 thực thể.
- **nodes**: sẽ là bộ dữ liệu chứa các đỉnh là các thực thể.

LƯU Ý: Đây chỉ là **DEMO** quy trình **Thu Thập Dữ Liệu**. Ngoài ra còn các bước làm sạch sâu và chuẩn hóa khác.

Phần **Xây dựng đồ thị** và **LOADER** sẽ được trình bày phía sau.

4 KHAI BÁO DỮ LIỆU VÀ CÁC THU VIỆN CẦN THIẾT

```
[1]: import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
import pickle
import torch
from infrastructure.pipelines import GraphTransformer
from application import AnalysisService, AIService
from core.logic import RapidFuzzySearch
```

4.0.1 Đọc dữ liệu

```
[2]: edges = pd.read_parquet('data_output/cleaned/edges.parquet', engine='pyarrow')
nodes = pd.read_parquet('data_output/cleaned/nodes.parquet', engine='pyarrow')
```

5 CẤU TRÚC DỮ LIỆU VÀ PHÂN TÍCH

Bây giờ ta sẽ thực hiện **LOADER** cho 2 bộ dữ liệu đã được xây dựng.

- Kiểm tra thông tin dữ liệu của dữ liệu.
- Kiểm tra lặp và null.
- Khám phá dữ liệu.

5.1 Đặc tả cấu trúc dữ liệu

Ý nghĩa của hai bộ dữ liệu **edges** và **nodes** – **edges**: Đây là tập cạnh **E** của đồ thị, chứa toàn bộ mối quan hệ giữa hai thực thể.

– **nodes**: Đây là tập đỉnh **V** của đồ thị, chứa toàn bộ thực thể và thuộc tính của nó.

```
[10]: print("Nodes:", len(nodes))
print("Edges:", len(edges))
```

Nodes: 4609499

Edges: 9665639

Ta sẽ dùng lệnh `len` để biết được số đỉnh và số cạnh của đồ thị:

– Đồ thị có ≈ 4.6 triệu đỉnh

– Đồ thị có ≈ 9.7 triệu cạnh

Tiếp theo, ta dùng lệnh `info()` để kiểm tra các thông số tổng quan về 2 bộ dữ liệu này

```
[11]: edges.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9665639 entries, 0 to 9665638
Data columns (total 9 columns):
#   Column          Dtype
#  :-----  :-----  :-----
```

```

---  -----  -----
0   person          object
1   person_label    object
2   relationship_label object
3   object          object
4   object_label    object
5   person_sub_type category
6   object_sub_type category
7   person_type     category
8   object_type     category

```

```
dtypes: category(4), object(5)
```

```
memory usage: 425.3+ MB
```

Tập dữ liệu này mô tả các cạnh (edges) trong đồ thị, thể hiện mối liên kết giữa các thực thể. | Trường dữ liệu | Kiểu dữ liệu | Ý nghĩa ngữ nghĩa | | :— | :—: | :— | | **person** | **object** | Mã định danh duy nhất (Wikidata ID) của thực thể nguồn. | | **person_name** | **object** | Tên hiển thị của thực thể nguồn. | | **person_sub_type** | **category** | Phân loại loại hình thực thể nguồn (ví dụ: Human, Organization). | | **relationship_label** | **category** | Nhãn mô tả bản chất mối quan hệ (ví dụ: *spouse*, *educated_at*). | | **object** | **object** | Mã định danh duy nhất (Wikidata ID) của thực thể đích. | | **object_name** | **object** | Tên hiển thị của thực thể đích. | | **object_sub_type** | **category** | Phân loại loại hình thực thể đích. |

```
[23]: nodes.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
Index: 4609521 entries, 0 to 4609534
```

```
Data columns (total 12 columns):
```

```

#   Column          Dtype
---  -----  ---
0   id            object
1   name          object
2   description    object
3   sub_type       category
4   type          category
5   birth_year     Int64
6   country       object
7   birth_place    object
8   occupation     object
9   interests      object
10  sex_or_gender  category
11  pyg_id         int64

```

```
dtypes: Int64(1), category(3), int64(1), object(7)
```

```
memory usage: 374.3+ MB
```

Tập dữ liệu này chứa thông tin chi tiết của các đỉnh (nodes), cung cấp đặc trưng ngữ nghĩa cho từng thực thể trong mạng lưới.

Để tổng quát hóa, chúng tôi đã tạo 1 cột type là cột đã được tổng quát hóa từ sub_type

Trường dữ liệu	Kiểu dữ liệu	Ý nghĩa ngữ nghĩa
id	object	Khóa chính, tương ứng với mã person hoặc object .
name	object	Tên gọi chính thức của thực thể.
description	object	Văn bản mô tả ngắn gọn về vai trò hoặc đặc điểm của thực thể.
birth_year	int64	Năm sinh (đối với người) hoặc năm thành lập (đối với tổ chức).
country	object	Quốc tịch hoặc quốc gia có mối liên hệ mật thiết.
birth_place	object	Địa danh nơi thực thể ra đời.
interests	object	Lĩnh vực quan tâm hoặc chuyên môn (dành cho thực thể con người).
sub_type	category	Nhân phân loại cụ thể của thực thể.
type	category	Nhân phân loại thực thể sau khi đã chuẩn hóa (Broad category).
occupation	object	Nghề nghiệp hoặc vị trí chuyên môn hiện tại.
sex_or_gender	object	Giới tính của thực thể nếu là con người.

```
[22]: nodes['sub_type'] = nodes['sub_type'].astype('category')
```

```
[40]: edges.head()
```

```
[40]:
```

	person	person_label	relationship_label	object	\
0	Q100035	Franz von Gaudy	educated_at	Q318186	
1	Q100286160	Peter Christian Wisbye	educated_at	Q1641001	
2	Q100286160	Peter Christian Wisbye	educated_at	Q12320313	
3	Q100329369	Pedro Gómez Sancho	educated_at	Q56400429	
4	Q100359119	Manuel Irujo Apeztegi	educated_at	Q633561	

	object_label	person_sub_type	\
0	Französisches Gymnasium Berlin	human	
1	Royal Danish Academy of Fine Arts	human	
2	Jonstrup Seminarium	human	
3	Royal College of Surgery of the Spanish Navy	human	
4	University of Zaragoza	human	

```

    object_sub_type
0      school
1    art academy
2 Teachers' seminar
3 college of surgery
4      university

```

```
[41]: nodes.head()
```

```

[41]:      id      name \
0      Q100      Boston
1  Q10000001  Tatyana Kolotilshchikova
2  Q100000136  Forest Lake State School
3  Q1000002    Claus Hammel
4  Q100000201  Min egen vei - fra Mao til Gud

      description \
0  thành phố thủ phủ tiểu bang Massachusetts, Hoa Kỳ
1  Soviet ballet dancer and teacher (1937-2016)
2  Forest Lake, QLD - Government - Primary - 865
3  East German playwright (1932-1990)
4  autobiography by Tania Michelet

      sub_type      type  birth_year \
0  city in the United States  organization  <NA>
1      human      human      1937
2      school  educational_institution  <NA>
3      human      human      1932
4  literary work      media      2020

      country  birth_place \
0  United States      None
1  Russia, Soviet Union  Nizhny Novgorod
2  Australia      None
3  Germany, Đức      Parchim
4      None      Na Uy

      occupation  interests  sex_or_gender \
0      None      None      NaN
1  ballet dancer      None      female
2      None      None      NaN
3  journalist, playwright, screenwriter, writer  None      male
4      None  tiểu sử      NaN

      pyg_id
0      0
1      0

```



```
2      0
3      1
4      0
```

Để hiểu rõ hơn về quy mô và tính đa dạng của mạng lưới, ta thực hiện phân tích số lượng các giá trị duy nhất (Unique values) và kiểm tra tính toàn vẹn của tập dữ liệu.

Sử dụng phương thức `.nunique()`, ta thu được bảng thống kê các định danh và thuộc tính quan hệ:

```
[47]: edges.nunique()
```

```
[47]: person          2830966
      person_label    2654410
      relationship_label  44
      object          2211626
      object_label    2009521
      person_sub_type      8
      object_sub_type   15531
      dtype: int64
```

Trường dữ liệu	Số lượng giá trị duy nhất	Nhận xét
person	2,830,966	Mỗi Q-ID là một định danh thực thể nguồn duy nhất.
person_label	2,654,410	Thấp hơn person do hiện tượng đồng âm (Homonyms).
person_sub_type	1	Chỉ tồn tại một loại duy nhất: human .
relationship_label	44	Tổng cộng 44 loại quan hệ xã hội/tổ chức khác nhau.
object	2,211,626	Số lượng thực thể đích đa dạng.
object_label	2,009,521	Tương tự thực thể nguồn, có sự trùng lặp nhân tên.
object_sub_type	15,531	Có 15,531 loại hình thực thể đích khác nhau.

```
[46]: nodes.nunique()
```

```
[46]: id          4609521
      name        4204835
      description  1834807
      sub_type     15536
      type         14
      birth_year   807
      country      18358
      birth_place  222481
```

```

occupation      267517
interests       206741
sex_or_gender    43
pyg_id          3247694
dtype: int64

```

Đối với danh mục thực thể, chúng ta tập trung vào sự phân hóa của các loại hình thực thể (Entity Types):

- **Tổng số loại đỉnh: 14 loại** (tương ứng với các nhóm đối tượng như *Education*, *Organization*, *Human*,...).
- **Đặc trưng kiểu dữ liệu:**
 - Các trường văn bản ngữ nghĩa: Kiểu `object` (chuỗi).
 - Các trường định danh: Kiểu `category` (phân loại)
 - Trường dữ liệu thời gian (`birthYear`): Kiểu `int64` (số nguyên), phục vụ cho các thuật toán lọc theo phân đoạn thời gian.

Tính nhất quán của đồ thị phụ thuộc vào việc loại bỏ các cạnh và đỉnh dư thừa. Chúng ta sử dụng lệnh `.duplicated().sum()` để kiểm tra:

```
[9]: edges.duplicated().sum()
```

```
[9]: np.int64(0)
```

```
[50]: nodes.duplicated().sum()
```

```
[50]: np.int64(0)
```

Kết quả cho ta thấy không có giá trị bị trùng (duplicated values).

Kết quả kiểm định: * **edges:** Không phát hiện bản ghi trùng lặp. * **nodes:** Không phát hiện bản ghi trùng lặp.

⇒ **Kết luận:** Tập dữ liệu đạt trạng thái **sạch** tuyệt đối về mặt cấu trúc. Mỗi dòng trong **edges** đại diện cho một liên kết vật lý duy nhất, và mỗi dòng trong **nodes** đại diện cho một thực thể duy nhất trong không gian tri thức. Điều này cho phép chúng ta khởi tạo đồ thị mà không cần các bước lọc trùng lặp bổ sung.

Sau khi xác thực tính toàn vẹn của dữ liệu, chúng ta tiến hành đi sâu vào phân tích đặc trưng topo (cấu trúc) và khám phá các quy luật phân phối ẩn sau các thực thể.

5.2 Thống kê và phân tích đặc trưng dữ liệu.

5.2.1 Có bao nhiêu đỉnh đối với từng loại đỉnh?

```
[4]: nodes['type'].value_counts()
```

```

[4]: type
human              3247681
written_work       438293

```

```
film          315908
work          193751
organization  132170
music         93942
position      72436
educational_institution  66650
awards        30779
event         12336
concept       5568
Name: count, dtype: int64
```


Do sự chênh lệch dữ liệu quá lớn (Long-tail Distribution) đặc trưng của đồ thị tri thức (3 triệu so với 5 ngàn). Nếu dùng thang đo thường, các nhóm nhỏ như Concept hay Event sẽ biến mất khỏi biểu đồ. Ta dùng Logarithmic Scale để có thể quan sát được sự tồn tại và tỷ lệ tương đối của tất cả các lớp dữ liệu trên cùng một khung hình.

```
[15]: plt.figure(figsize=(12, 8))

sns.countplot(
    data=nodes,
    y='type',
    order=nodes['type'].value_counts().index,
    palette=sns.color_palette("viridis", 11),
    hue='type',
    legend=False
)

plt.xscale('log')

plt.margins(x=0.15)
plt.tight_layout()
plt.show()
```



Đồ thị mang tính chất **Dị thể (Heterogeneous)** rõ nét với **11** loại đỉnh khác nhau. Qua thống kê, thực thể **human** chiếm tỷ trọng áp đảo, đóng vai trò là các nút trung tâm kết nối đến các thực thể hỗ trợ như tổ chức, trường học và tác phẩm sáng tạo.

5.2.2 Thống kê số bậc (số mối quan hệ) của một người?

```
[16]: person_degree = edges.groupby('person').size()

print(f"Bậc trung bình: {person_degree.mean()}")
print(f"Bậc cao nhất: {person_degree.max()}")
print(f"Bậc thấp nhất: {person_degree.min()}")
```

Bậc trung bình: 3.8014516615017575

Bậc cao nhất: 66566

Bậc thấp nhất: 1

Bậc của một đỉnh (k) đại diện cho số lượng kết nối trực tiếp. Trung bình mỗi cá nhân trong mạng lưới có từ **3-4 mối quan hệ** được ghi nhận chính thức. Tuy nhiên, sự phân hóa giữa nhóm người dùng thông thường và các “Hubs” (nút siêu kết nối) là cực kỳ lớn.

Chúng ta sử dụng biểu đồ **Log-Log** để quan sát hàm phân phối tích lũy bổ sung (CCDF).

Tại sao dùng Log-Log?

—Trong mạng lưới quy mô lớn, thang đo tuyến tính thường bị “nhiều” ở vùng dữ liệu nhỏ. Thang đo Log giúp nén các khoảng cách khổng lồ, làm lộ diện cấu trúc mạng lưới. Nếu các điểm dữ liệu

tạo thành đường thẳng dốc xuống, mạng lưới tuân theo quy luật hàm lũy thừa (Power-law).

Biểu đồ cho thấy điều gì?

- Quy luật Hàm lũy thừa (Power-law): Khi các điểm dữ liệu tạo thành một đường thẳng dốc xuống, điều đó chứng minh mạng lưới không phải kết nối ngẫu nhiên mà có cấu trúc “Scale-free”.
- Sự phân hóa quyền lực: Nó cho thấy một thực tế rằng số đông người dùng chỉ có rất ít kết nối, trong khi một số ít cá nhân (Hubs) lại nắm giữ sức ảnh hưởng khổng lồ lên toàn bộ hệ thống.

Thông số:

- Trục hoành (k): Quy mô kết nối (Bậc). Càng về bên phải, số lượng kết nối càng khổng lồ.
- Trục Tung (P(k)): Tần suất xuất hiện. Càng lên cao, số lượng người có bậc đó càng nhiều.
- Hệ số : Độ dốc của đường thẳng, đại diện cho mức độ tập trung quyền lực của mạng lưới.

```
[60]: person_degree = edges.groupby('person').size()

degree_counts = person_degree.value_counts().sort_index()
pdf = degree_counts / degree_counts.sum()

# 2. Tính toán CCDF:  $P(K \geq k)$ 
# Lấy 1 trừ đi xác suất lũy tích (CDF)
# shift(1) và fillna(0) để đảm bảo tại bậc k, ta tính cả xác suất của chính k
ccdf = 1 - pdf.cumsum().shift(1).fillna(0)


plt.loglog(ccdf.index, ccdf.values,
            marker='o',
            linestyle='none',
            markersize=8,
            alpha=0.6,
            color='#1f77b4',
            markeredgecolor='white',
            markeredgewidth=1)

plt.xlabel('Bậc (k) [Thang đo Log]', fontsize=14, fontweight='bold')
plt.ylabel('$P(K \geq k)$ [Thang đo Log]', fontsize=14, fontweight='bold')
plt.title('Phân phối Bậc (CCDF) - Scale-free Analysis', fontsize=16, pad=20)

sns.despine()

plt.tight_layout()
plt.show()
```

Phân phối Bậc (CCDF) - Scale-free Analysis



Hệ số γ giúp phân loại bản chất mạng lưới. Chúng ta sử dụng phương pháp ước lượng hợp lý cực đại (**Maximum Likelihood Estimation - MLE**):

$$\gamma = 1 + n \left(\sum_{i=1}^n \ln \frac{k_i}{k_{min} - 0.5} \right)^{-1}$$

Trong đó:

- $\hat{\gamma}$: Hệ số mũ đặc trưng của quy luật hàm lũy thừa (Power-law exponent).
- n : Tổng số nút trong mạng lưới có bậc thỏa mãn điều kiện $k_i \geq k_{min}$.
- k_i : Bậc (số lượng kết nối) của nút thứ i trong tập dữ liệu.
- k_{min} : Ngưỡng bậc tối thiểu mà tại đó quy luật Power-law bắt đầu có hiệu lực.
- $\ln$: Logarit tự nhiên (cơ số e).

Phân loại mạng lưới:

- $1 < \gamma \leq 2$: Tập trung cực độ
- $2 < \gamma < 3$: Mạng không tỷ lệ (Scale-free)
- $\gamma \geq 3$: Mạng ngẫu nhiên (Random-like)

```
[17]: x = np.array(person_degree)

k_min = 100

x_filtered = x[x >= k_min]
n = len(x_filtered)

# 4. Áp dụng công thức MLE (Clauset et al., 2009)
# Tính tổng log(k_i / (k_min - 0.5))
sum_log = np.sum(np.log(x_filtered / (k_min - 0.5)))

# Tính gamma
gamma = 1 + n * (sum_log)**-1

print(gamma)
```

3.352410172075286

Ta thấy nơi tập trung trải đều ở bậc 100, do đó chọn $k_{min} = 100$

Tính ra được $\gamma \approx 3.4 \geq 3$


→ Cho thấy mạng lưới có xu hướng tiệm cận **Mạng ngẫu nhiên (Random-like)**. Điều này chỉ ra rằng các nút siêu kết nối (Hubs) hiện tại chưa đủ mật độ để bẻ lái toàn bộ đồ thị theo cấu trúc tập trung quyền lực tuyệt đối (Scale-free hoàn toàn).

5.2.3 Độ tuổi nào chiếm đa số mạng lưới?

```
[64]: # Chuyển về số nếu chưa chuyển
years = pd.to_numeric(nodes['birth_year'], errors='coerce')

# Vẽ biểu đồ phân phối tuổi
years.hist(bins=range(1800, 2025, 5)) # Gom nhóm 5 năm một
```

[64]: <Axes: >



Ta thấy được các thực thể có nhiều mạng lưới nằm trong 1950-1980.

5.2.4 Top 10 người có nhiều mối quan hệ nhất

Danh sách 10 người có bậc cao nhất đại diện cho những “Social Hubs” – những người đóng vai trò quan trọng nhất trong việc rút ngắn khoảng cách giữa các cá nhân bất kỳ trong mạng lưới.

```
[67]: # 1. Đếm số lần xuất hiện của từng ID (đảm bảo tính duy nhất)
counts = edges['person'].value_counts().reset_index()
counts.columns = ['id', 'count']

# 3. Gắn tên lại vào bảng đếm bằng phép Merge (tương tự JOIN trong SQL)
result = counts.merge(nodes, on='id', how='left')

# 4. Sắp xếp và lấy Top 10
result[['id', 'name', 'count']].head(10)
```

```
[67]:
```

	id	name	count
0	Q6283171	Joseph Foster	66566
1	Q45765	Jack London	8413
2	Q42511	H. G. Wells	6717
3	Q1229835	Hans Gärtner	3479
4	Q88964	Friedrich Münzer	2948

5	Q1697841	Johannes Kirchner	2787
6	Q285048	Randall Munroe	2203
7	Q711593	Arthur Stein	1976
8	Q65666	Otto Seeck	1950
9	Q4441	Emily Dickinson	1827

H. G. Wells: Nhà văn Anh tiên phong, “Cha đẻ của khoa học viễn tưởng” với các kiệt tác định hình thể loại như *Cỗ máy thời gian (1895)* và *Chiến tranh giữa các thế giới (1898)*.

Jack London: Tác giả người Mỹ lỗi lạc, nổi tiếng với những tiểu thuyết phiêu lưu kinh điển về thiên nhiên hoang dã như *Tiếng gọi nơi hoang dã (1903)* và *Nanh trắng (1906)*.

Emily Dickinson: Nữ sĩ trụ cột của văn học Mỹ, để lại di sản đồ sộ với hơn 1.800 bài thơ sâu sắc, tiêu biểu là các tác phẩm về sự bất tử như *“Because I could not stop for Death”*.

Randall Munroe: Cựu kỹ sư NASA, tác giả của webcomic khoa học nổi tiếng *xkcd* và cuốn sách giải thích khoa học bán chạy nhất thế giới *What If? (Sẽ ra sao nếu?)*.

```
[68]: # 1. Đếm số lần xuất hiện của từng ID (đảm bảo tính duy nhất)
counts = edges['object'].value_counts().reset_index()
counts.columns = ['id', 'count']

# 3. Gắn tên lại vào bảng đếm bằng phép Merge (tương tự JOIN trong SQL)
result = counts.merge(nodes, on='id', how='left')

# 4. Sắp xếp và lấy Top 10
result[['id', 'name', 'count']].head(10)
```

```
[68]:      id      name  count
0    Q432      Hồi giáo  60483
1    Q9592  Catholic Church  42770
2    Q29468  Đảng Cộng hòa  29063
3    Q29552  Democratic Party  27635
4  Q10855271  Knight of the Legion of Honour  21231
5    Q13371  Harvard University  20721
6    Q112197  Righteous Among the Nations  17809
7    Q79854  Communist Party of the Soviet Union  17581
8    Q1316544  Guggenheim Fellowship  17387
9    Q185493  Order of Lenin  16578
```

Hồi giáo: Một trong những tôn giáo lớn nhất hành tinh với hơn 2 tỷ tín đồ, có tầm ảnh hưởng sâu rộng đến lịch sử và địa chính trị thế giới; tiêu biểu với kinh điển *Kinh Qur'an*.

Giáo hội Công giáo: Định chế Kitô giáo lớn nhất thế giới với tầm ảnh hưởng văn hóa sâu sắc suốt nhiều thế kỷ; tiêu biểu với trung tâm quyền lực là *Tòa thánh Vatican*.

Đại học Harvard: Biểu tượng hàng đầu của giáo dục tinh hoa toàn cầu và là đại học lâu đời nhất Hoa Kỳ; tiêu biểu với mạng lưới cựu sinh viên gồm nhiều *Tổng thống Mỹ và chủ nhân giải Nobel*.

Đảng Dân chủ: Một trong hai chính đảng lâu đời nhất thế giới còn hoạt động tại Hoa Kỳ; tiêu

biểu với các chương trình nghị sự về *An sinh xã hội và Biến đổi khí hậu* dưới các thời kỳ tổng thống như Franklin D. Roosevelt hay Barack Obama.

5.2.5 Top 10 loại quan hệ được ưu tiên nhất

```
[70]: top_10 = edges['relationship_label'].value_counts().head(10)
      print(top_10)
```

```
relationship_label
educated_at      1714215
work_at          1669322
award_received   1313055
performed_by     1019990
acted_in         1019976
held_position     840756
father           480367
author_of        377995
mother           347322
director         295427
Name: count, dtype: int64
```

→ Mỗi quan hệ `educated_at` (giáo dục) là sợi dây liên kết phổ biến nhất. Điều này khẳng định môi trường học thuật là yếu tố quan trọng nhất tạo ra các kết nối xã hội bền vững trên Wikidata.

5.2.6 Top 10 sở thích

```
[73]: s_interests = nodes[nodes.interests.notna()].interests.astype(str).str.
      ↪split(r',\s*')
      df_exploded = s_interests.explode()
      df_exploded.value_counts().head(10)
```

```
[73]: interests
      phim chính kịch      69447
      bóng rổ              48557
      giọng hát           47823
      bóng đá             37159
      bóng bầu dục Mỹ     35141
      phim hài            34411
      phim câm            27245
      phim tài liệu       18472
      bóng chày           17626
      dương cầm          14987
      Name: count, dtype: int64
```

5.2.7 Top 10 nghề nghiệp được ưu chuộng nhất.

```
[74]: s_occupation = nodes[nodes.occupation.notna()].occupation.astype(str).str.  
      ↪split(r',\s*')  
df_oc_exploded = s_occupation.explode()  
df_oc_exploded.value_counts().head(10)
```

```
[74]: occupation  
politician          481062  
university teacher  145552  
writer             138608  
actor              131459  
journalist          76036  
lawyer              60562  
painter            56439  
researcher          53284  
film actor          49540  
film director       48757  
Name: count, dtype: int64
```

Chúng ta thực hiện phân tích **Co-occurrence** (Sự đồng xuất hiện) để tìm ra các mẫu hành vi và chuyên môn thường đi đôi với nhau.

Dựa trên kỹ thuật phân tách chuỗi đa trị (Exploding), chúng ta phát hiện các cặp tương quan đặc trưng:

5.2.8 Những sở thích nào hay đi chung với nhau?

```
[76]: from itertools import combinations  
      from collections import Counter  
  
pairs = []  
for interest_list in s_interests:  
    clean_list = sorted([i for i in interest_list if i])  
    if len(clean_list) >= 2:  
        pairs.extend(combinations(clean_list, 2))  
  
common_pairs = Counter(pairs).most_common(20)  
print("Các cặp sở thích hay đi cùng nhau:")  
for i, common_pair in enumerate(common_pairs):  
    print(f"{i}: {common_pair}")
```

Các cặp sở thích hay đi cùng nhau:

```
0: (('phim chính kịch', 'phim âm'), 7049)  
1: (('giọng hát', 'nhạc pop'), 5641)  
2: (('ghi-ta', 'giọng hát'), 5550)  
3: (('phim chính kịch', 'phim lãng mạn'), 5165)  
4: (('phim chính kịch', 'phim hình sự'), 4134)  
5: (('phim chính kịch', 'phim hài'), 3799)
```

6: (('phim chính kịch', 'phim giết gân'), 2750)
 7: (('dương cầm', 'giọng hát'), 2630)
 8: (('phim chính kịch', 'phim hành động'), 2485)
 9: (('phim chính kịch', 'phim tiểu sử'), 2226)
 10: (('giọng hát', 'nhạc rock'), 2081)
 11: (('dương cầm', 'nhạc cổ điển'), 1895)
 12: (('phim chiến tranh', 'phim chính kịch'), 1865)
 13: (('phim giết gân', 'phim hành động'), 1855)
 14: (('giọng hát', 'nhạc hip hop'), 1717)
 15: (('dương cầm', 'jazz'), 1676)
 16: (('phim câm', 'phim hài'), 1632)
 17: (('ghi-ta', 'nhạc rock'), 1623)
 18: (('film based on a novel', 'phim chính kịch'), 1618)
 19: (('giọng hát', 'opera'), 1567)

Cặp tương quan	Ý nghĩa thực tế
Văn học – Báo chí	Nhóm trí thức có thiên hướng hoạt động đa năng trong lĩnh vực ngôn luận.
Diễn viên – Điện ảnh	Xu hướng chuyên môn hóa cao trong ngành công nghiệp giải trí.
Luật sư – Chính trị gia	Phản ánh lộ trình sự nghiệp điển hình của các nhà lãnh đạo xã hội.
Lịch sử – Giảng viên	Sự gắn kết chặt chẽ giữa chuyên môn nghiên cứu và đào tạo.

5.2.9 Những nghề nghiệp nào hay đi cùng nhau?

```
[77]: from itertools import combinations
      from collections import Counter

      pairs = []
      for occupation_list in s_occupation:
          clean_list = sorted([i for i in occupation_list if i])
          if len(clean_list) >= 2:
              pairs.extend(combinations(clean_list, 2))

      common_pairs = Counter(pairs).most_common(15)
      print("Các cặp nghề nghiệp hay đi cùng nhau:")
      for i, common_pair in enumerate(common_pairs):
          print(f"{i}: {common_pair}")
```

Các cặp nghề nghiệp hay đi cùng nhau:

0: (('actor', 'film actor'), 34256)
 1: (('lawyer', 'politician'), 33551)
 2: (('film director', 'screenwriter'), 25087)
 3: (('actor', 'television actor'), 24851)
 4: (('journalist', 'writer'), 23759)

```

5: (('poet', 'writer'), 21686)
6: (('film actor', 'television actor'), 20060)
7: (('film actor', 'stage actor'), 15414)
8: (('Catholic bishop', 'Catholic priest'), 15146)
9: (('actor', 'film director'), 13798)
10: (('journalist', 'politician'), 12541)
11: (('historian', 'university teacher'), 12520)
12: (('actor', 'singer'), 12410)
13: (('actor', 'screenwriter'), 12082)
14: (('pensioner', 'politician'), 11907)

```

Ta thấy được: - Hầu hết diễn viên trên thế giới đóng phim điện ảnh nhiều hơn phim truyền hình. - Những người thích lịch sử thì thường làm giảng viên đại học. - Luật sư thì thường là chính trị gia.

6 PHÂN TÍCH VÀ THỐNG KÊ CHUYÊN SÂU

6.1 Chuyển đổi cấu trúc đồ thị

Để thực hiện các phân tích xã hội phức tạp như số liên kết ta cần 1 **cấu trúc đồ thị** thực thụ, ta sẽ sử dụng thư viện `igraph`.

Xây dựng **Đồ thị quan hệ** với lớp `GraphTransformer`

Lớp `GraphTransformer` đóng vai trò là **Transformer** trong dữ liệu (ETL), chịu trách nhiệm kiến tạo đồ thị từ các tập dữ liệu đã được làm sạch.

Chức năng của hàm `covert_to_graph`

Hàm `covert_to_graph(edges, nodes)` thực hiện phép ánh xạ dữ liệu bảng (Tabular Data) sang cấu trúc đồ thị (Graph Structure).

- **Đầu vào:**
 - `nodes`: DataFrame chứa thông tin thực thể (Vertex data).
 - `edges`: DataFrame chứa thông tin liên kết (Edge data).
- **Đầu ra:** Một đối tượng `igraph.Graph` (Heterogeneous Graph).

```
[3]: transformer = GraphTransformer()
graph = transformer.build_graph(edges, nodes)
```

`GraphTransformer` initialized.

- Đã index 4609499 nodes.
- Đang mapping cạnh...
- Số lượng cạnh hợp lệ: 9665639
- Đang xây dựng cấu trúc đồ thị...

Hoàn tất chuyển đổi!

Trong các dự án dữ liệu lớn, việc xây dựng lại đồ thị từ đầu mỗi khi thực thi có thể gây tốn kém tài nguyên và thời gian. Chúng ta sử dụng cơ chế **Serialization** thông qua thư viện `pickle` để lưu trữ và tái sử dụng cấu trúc đồ thị đã được xử lý.

```
[17]: graph_path = 'data_output/graph/relationship_graph.pkl'
      with open(graph_path, "rb") as file:
          graph = pickle.load(file)
```

Tiếp theo, ta sẽ thực hiện **LOADER** cho đồ thị, kiểm tra đồ thị và bộ dữ liệu.

– Để xác nhận quá trình nạp dữ liệu thành công và không xảy ra sai lệch cấu trúc, chúng ta thực hiện đối soát (Sanity Check) giữa các chỉ số của đồ thị và dữ liệu Pandas gốc thông qua các hàm nội tại của igraph:

`graph.vcount()`: Trả về tổng số lượng đỉnh (Vertices).

`graph.ecount()`: Trả về tổng số lượng cạnh (Edges).

```
[4]: graph.vcount() == len(nodes)
```

```
[4]: True
```

```
[5]: graph.ecount() == len(edges)
```

```
[5]: True
```

– Số đỉnh của graph bằng với số dòng của nodes.

– Số cạnh của graph bằng với số dòng của edges.

→ Chuyển đổi **an toàn**, sẵn sàng cho các thuật toán phân tích mạng lưới phức tạp.

6.2 Thực nghiệm và Kiểm chứng “*Lý thuyết sáu bậc phân cách*”

Để khai thác sức mạnh của đồ thị tri thức, hệ thống được trang bị hai lớp xử lý chuyên biệt: một để giải quyết vấn đề ngôn ngữ tự nhiên (Tìm kiếm mờ) và một để xử lý logic đồ thị (Phân tích lộ trình).

Công cụ tìm kiếm mờ: RapidFuzzySearch Trong thực tế, người dùng thường nhập tên thay vì mã định danh (Q-ID). Lớp **RapidFuzzySearch** đóng vai trò là “cầu nối” chuyển đổi tên thực thể sang `internal_id` của đồ thị, hỗ trợ cả trường hợp người dùng nhập sai chính tả. * **Cơ chế:** Sử dụng thuật toán so khớp mờ (Fuzzy Matching) dựa trên khoảng cách chỉnh sửa (**Levenshtein Distance**). * **Toán học:** Điểm tương đồng được tính dựa trên số phép biến đổi tối thiểu (thêm, xóa, thay thế) giữa hai chuỗi ký tự s_1 và s_2 :

$$score(s_1, s_2) \propto \frac{1}{d(s_1, s_2) + 1}$$

Phương thức	Tham số	Kết quả trả về
<code>quick_get_id</code>	<code>query_name</code>	Trả về <code>internal_id</code> (index) chính xác nhất trong <code>nodes</code> .

Dịch vụ phân tích đồ thị: AnalysisService Lớp này cung cấp các dịch vụ tính toán trực tiếp trên đối tượng `igraph`.

Hàm `find_connection(a, b, draw)`

- **Cơ chế:** Tự động nhận diện đầu vào (Tên hoặc ID). Nếu là Tên, hàm sẽ gọi `RapidFuzzySearch` để giải mã ID. Sau đó, thuật toán tìm đường đi ngắn nhất (**Shortest Path**) sẽ được thực thi trên đồ thị dị thể.
- **Tham số draw:** Nếu là `True`, hệ thống sẽ trực quan hóa lộ trình liên kết dưới dạng biểu đồ mạng lưới.

```
[3]: search_engine = RapidFuzzySearch(nodes)
      analysis = AnalysisService(graph)
```

LOG: Đang xây dựng chỉ mục tìm kiếm...

LOG: Đã tạo xong Index với 4190857 từ khóa.

6.2.1 Thử nghiệm thực tế

Chúng ta sử dụng hàm `find_connection` để kiểm tra khả năng liên kết giữa các nhân vật nổi tiếng, đại diện cho các “Hub” xã hội khác nhau.

Ví dụ 1: Sơn Tùng M-TP $\iff$ Taylor Swift Ta sẽ sử dụng công cụ tìm kiếm mờ để lấy ID và tìm lộ trình

```
[6]: id_a = search_engine.quick_get_id("taylor swift")
      id_b = search_engine.quick_get_id("Sơn tùng mtp")
```

Đang tìm: 'taylor swift'...

Có 2 người tên giống vậy. Vui lòng chọn:

[0] Taylor Swift (human) (DESC: nữ ca sĩ kiêm nhạc sĩ sáng tác bài hát người Mỹ (sinh 1989) - ID: 2258704

[1] Taylor Swift (media) (DESC: album phòng thu năm 2006 của Taylor Swift - ID: 4283812

Nhập số thứ tự (index): 0

-> Đã chọn Taylor Swift (ID: 2258704)

Đang tìm: 'Sơn tùng mtp'...

-> Đã chọn: Sơn Tùng M-TP (ID: 1761990)

Ta thấy được:

– Sơn Tùng M-TP có id là 910010

– Taylor Swift có id là 4373555

Ta thực hiện tìm đường đi dựa trên hai id tìm được bằng hàm `find_connection`

```
[7]: path = analysis.find_connection(id_a, id_b, draw = True)
```

Đã tìm thấy liên kết!

KẾT QUẢ TÌM ĐƯỜNG:

01. Taylor Swift [Q26876]

(award_received)
02. American Music Award for Favorite Pop/Rock Female Artist [Q1441929]

(award_received)
03. Mariah Carey [Q41076]

(influenced_by)
04. Mỹ Linh [Q6945890]

(educated_at)
05. Vietnam National Academy of Music [Q5649320]

(educated_at)
06. Nguyễn Ánh Tuyết [Q118249221]

(work_at)
07. Conservatory of Ho Chi Minh City [Q1377237]

(educated_at)
08. Sơn Tùng M-TP [Q17450386]

Kết quả: Tìm thấy lộ trình kết nối với 4 bậc trung gian.

→ Điều này minh chứng cho sự giao thoa mạnh mẽ giữa văn hóa đại chúng Việt Nam và Quốc tế thông qua các nền tảng số hóa.

Ví dụ 2: Chủ tịch Hồ Chí Minh $\iff$ Taylor Swift Ta sẽ thử tìm đường liên kết giữa Bác Hồ và Taylor Swift.

Dùng find_connection với tên.

```
[8]: path = analysis.find_connection("Hồ Chí Minh", "Taylor Swift", draw = True)
```

Đang tìm: 'Hồ Chí Minh'...

-> Đã chọn: Ho Chi Minh (ID: 2585288)

Đang tìm: 'Taylor Swift'...

Có 2 người tên giống vậy. Vui lòng chọn:

[0] Taylor Swift (human) (DESC: nữ ca sĩ kiêm nhạc sĩ sáng tác bài hát người Mỹ (sinh 1989) - ID: 2258704

[1] Taylor Swift (media) (DESC: album phòng thu năm 2006 của Taylor Swift - ID: 4283812

Nhập số thứ tự (index): 0

-> Đã chọn Taylor Swift (ID: 2258704)

Đã tìm thấy liên kết!

KẾT QUẢ TÌM ĐƯỜNG:

01. Ho Chi Minh [Q36014]

(award_received)

02. Star of the Republic of Indonesia [Q2340171]
- (award_received)
03. Elizabeth II [Q9682]
- (award_received)
04. honorary doctor of the Royal College of Music [Q99025668]
- (award_received)
05. Andrew Lloyd Webber [Q180975]
- (composer)
06. Beautiful Ghosts [Q72270672]
- (lyricist)
07. Taylor Swift [Q26876]

Kết quả: Đường đi được tìm thấy với độ dài cực ngắn.

→ Cho thấy các nhân vật lịch sử và hiện đại luôn tồn tại những “mắt xích” chung thông qua quốc gia, giáo dục hoặc các tổ chức chính trị - xã hội.

6.2.2 Kiểm chứng quy mô lớn: Lý thuyết Sáu bậc phân cách

Để đưa ra kết luận mang tính khoa học thay vì chỉ dựa vào các trường hợp cá biệt, chúng ta tiến hành thực nghiệm thống kê trên diện rộng để xác định cấu trúc liên kết toàn cục của mạng lưới.

– **Lý thuyết sáu bậc:** Tất cả mọi người trên thế giới nếu có liên kết sẽ chỉ liên kết tối đa 6 bậc trung gian.

– Dùng hàm `find_degree(id_a, id_b)` của lớp **AnalysisService**: Hàm này chỉ trả về số bậc.

– Ta sẽ lấy mẫu ngẫu nhiên 100,000 mẫu để thử.

Thiết lập thực nghiệm

- **Giả thuyết (H_0):** Khoảng cách trung bình giữa hai thực thể bất kỳ trong mạng lưới tri thức luôn ≤ 6 .
- **Phương pháp thực nghiệm:**
 1. **Lấy mẫu ngẫu nhiên (Random Sampling):** Trích xuất **100,000 cặp** thực thể (u, v) từ tập đỉnh V của đồ thị.
 2. **Tính toán khoảng cách:** Sử dụng hàm `find_degree(id_a, id_b)` để tính toán đường đi ngắn nhất (Geodesic distance) mà không cần truy xuất lộ trình đầy đủ nhằm tối ưu hóa hiệu suất.
 3. **Thống kê:** Tổng hợp dữ liệu để tính toán đường đi trung bình L và vẽ biểu đồ phân phối tần suất khoảng cách.

Lý thuyết Watts và Strogatz Theo lý thuyết của Watts và Strogatz về mạng lưới **Small-world**, đường đi ngắn nhất trung bình (L) kỳ vọng sẽ xấp xỉ giá trị:

$$L_{theory} \approx \frac{\ln(N)}{\ln(\langle k \rangle)}$$

Dựa vào các thông số đã thống kê được từ tập dữ liệu: * Tổng số nút (N): 2,869,142 * Bậc trung bình ($\langle k \rangle$): ≈ 3.8

Ta có giá trị kỳ vọng lý thuyết:

$$L_{theory} \approx \frac{\ln(2,869,142)}{\ln(3.8)} \approx \frac{14.87}{1.33} \approx 11.1$$

Quy trình thực thi kiểm chứng Việc tính toán được thực hiện thông qua vòng lặp hiệu năng cao, thu thập dữ liệu về số bậc của 100,000 cặp mẫu để xây dựng biểu đồ phân phối:

1. **Tính toán chỉ số khoảng cách:** Thực hiện đo $d(u, v)$ cho từng cặp mẫu.
2. **Phân tích phân phối:** Nếu phần lớn kết quả hội tụ tại các giá trị $d \in [2, 6]$, điều đó chứng minh tính đúng đắn của giả thuyết “Sáu bậc phân cách” trên thực thể số.

Nhận định: Kết quả của thực nghiệm này là bằng chứng thực nghiệm quan trọng nhất để khẳng định khả năng kết nối không biên giới của tri thức nhân loại được số hóa trên nền tảng Wikidata.

```
[5]: import time
from tqdm import tqdm
num_samples = 100000
num_nodes = graph.vcount()
src_indices = np.random.randint(0, num_nodes, num_samples)
dst_indices = np.random.randint(0, num_nodes, num_samples)

distances = []
unreachable_count = 0
same_node_count = 0
all_pairs = list(zip(src_indices, dst_indices))

start_time = time.time()

degrees = analysis.compute_degrees_parallel(all_pairs, batch_size=2000)

end_time = time.time()

unreachable_count = np.sum(degrees == 0)
distances = degrees[degrees > 0]
```

Batch Processing: 100% | 1/1 [00:00<00:00, 1.61it/s]

Số người kết nối thành công

```
[32]: stats = pd.DataFrame({'degree':distances})
```

```
[33]: stats.describe()
```

```
[33]:          degree
count  79969.000000
mean    3.513949
std     1.816715
min     1.000000
25%     2.000000
50%     3.000000
75%     4.000000
max     24.000000
```

```
[35]: stats.value_counts(normalize=True)
```

```
[35]: degree
3      0.433556
2      0.245433
4      0.156098
5      0.056997
6      0.035051
7      0.024184
8      0.015544
9      0.010654
10     0.006965
1      0.004689
11     0.004027
12     0.002551
13     0.001250
14     0.000975
15     0.000563
16     0.000500
17     0.000388
18     0.000275
19     0.000150
20     0.000050
21     0.000038
22     0.000038
24     0.000025
Name: proportion, dtype: float64
```

Số người kết nối không thành công, do đồ thị bị chia cắt thành nhiều đảo nhỏ

```
[9]: unreachable_count
```

```
[9]: np.int64(20031)
```

Ta thấy trung bình các bậc ≈ 3.5

So sánh và Kiểm chứng Giả thuyết Chúng ta sẽ đối chiếu kết quả thực nghiệm ($\bar{d}$) với giả thuyết Sáu bậc phân cách thông qua bảng tiêu chí sau:

Chỉ số so sánh	Thực nghiệm ($\bar{d}$)	Lý thuyết (L_{theory})	Ý nghĩa
Giá trị trung bình	≈ 3.5 Tính từ 100,000 mẫu	≈ 11.1 (Ngẫu nhiên)	Nếu $\bar{d} \leq 6$, đồ thị có tính kết nối cực cao.
Phân phối	Histogram tần suất	Hình chuông (Bell curve)	Xác định xem “Sáu bậc” là giá trị trung bình hay giá trị tối đa.
Độ lệch chuẩn	σ đo được	Càng nhỏ càng tốt	Cho thấy mức độ ổn định của cấu trúc mạng lưới.

```
[36]: mean_val = np.mean(distances)
      median_val = np.median(distances)
      std_val = np.std(distances)

      plt.figure(figsize=(10, 6))

      sns.histplot(distances, kde=True, bins=50, color='skyblue', edgecolor='black',
                    alpha=0.6)

      plt.axvline(mean_val, color='red', linestyle='--', linewidth=2,
                  label=f'Mean: {mean_val:.2f}')
      plt.axvline(median_val, color='green', linestyle='-', linewidth=2,
                  label=f'Median: {median_val:.2f}')
```


```
plt.axvline(mean_val - std_val, color='purple', linestyle=':', linewidth=1.5,
            label=f'Std Dev ( $\pm 1$ ): {std_val:.2f}')
plt.axvline(mean_val + std_val, color='purple', linestyle=':', linewidth=1.5)
plt.axvspan(mean_val - std_val, mean_val + std_val, color='purple', alpha=0.1,
            label='Khoảng biến thiên 1 ')

plt.title('Phân phối "Khoảng cách Xã hội"', fontsize=14)
plt.xlabel('Khoảng cách liên kết', fontsize=12)
plt.ylabel('Số lượng cặp', fontsize=12)

plt.legend(frameon=True, shadow=True)

plt.grid(True, alpha=0.3)
plt.tight_layout()

plt.show()
```



Từ kết quả cho thấy: Đồ thị lệch phải, với **trung bình là 3.51** và **độ lệch chuẩn là 1.82** cho thấy phần lớn các cặp người dùng có khoảng cách ngắn, chỉ khi một số ít có khoảng cách xa. Điều này cho thấy đồ thị có tính kết nối cao, phù hợp với giả thuyết Sáu bậc phân cách.

Kết luận Do $\bar{d} \leq 6$: Ta chấp nhận giả thuyết H_0 . Mạng lưới tri thức Wikidata thực sự là một “Thế giới nhỏ”, nơi mọi thực thể đều có sợi dây liên kết chặt chẽ.

7 MÔ HÌNH DỰ ĐOÁN LIÊN KẾT

Sau khi phân tích cấu trúc topo và kiểm chứng lý thuyết “Sáu bậc”, bước tiếp theo là xây dựng một hệ thống trí tuệ nhân tạo có khả năng dự báo các mối quan hệ tiềm ẩn trong tương lai.

7.1 Giới thiệu về kiến trúc GraphSAGE

Trước khi đi sâu vào chi tiết kỹ thuật, cần làm rõ các nguyên lý nền tảng mà mô hình sử dụng để giải quyết bài toán trên Đồ thị Tri thức (Knowledge Graph).

7.1.1 Lịch sử & Nguồn gốc

Mô hình nền tảng em sử dụng là GraphSAGE (Graph Sample and Aggregate).

Tác giả: Hamilton et al. (Stanford University).

Năm công bố: 2017 (Được công bố tại hội nghị NeurIPS - hội nghị AI hàng đầu thế giới).

7.1.2 Tại sao lại là Graph Neural Network (GNN)?

Các phương pháp học máy truyền thống thường coi dữ liệu là các điểm độc lập (i.i.d). Tuy nhiên, trong Đồ thị Tri thức, sức mạnh nằm ở **mối liên kết**. Một thực thể (ví dụ: “Barack Obama”) không chỉ được định nghĩa bởi tên gọi, mà còn bởi những ai ông ấy kết nối tới (vợ, nơi làm việc, đảng phái).

Graph Neural Network (GNN) là kiến trúc mạng nơ-ron chuyên biệt cho phép “nhúng” (embed) thông tin cấu trúc này. Nó cho phép một node “nhìn” thấy hàng xóm của mình và học hỏi từ họ.

Lý do 1: Tính quy nạp (Inductive Learning). – Các mô hình cũ (GCN, TransE) là Transductive: Chúng học thuộc lòng vị trí của node. Nếu có một người mới (New User) tham gia vào đồ thị, mô hình cũ phải train lại từ đầu mới dự đoán được.

– GraphSAGE là Inductive: Nó không học thuộc lòng, mà học “cách tổng hợp thông tin từ hàng xóm”. Do đó, khi có node mới, chỉ cần biết hàng xóm của nó là ai, mô hình có thể tạo vector nhúng (Embedding) và dự đoán ngay lập tức mà không cần train lại. Đây là yêu cầu bắt buộc cho hệ thống thực tế.

Lý do 2: Khả năng mở rộng (Scalability). – GraphSAGE sử dụng kỹ thuật Neighbor Sampling (Lấy mẫu hàng xóm). Thay vì tính toán trên toàn bộ đồ thị (gây tràn bộ nhớ với 4.5 triệu node), nó chỉ lấy mẫu cục bộ (ví dụ: 20 hàng xóm cấp 1, 10 hàng xóm cấp 2). Điều này cho phép huấn luyện trên các đồ thị khổng lồ (Mini-batch Training).

7.1.3 Lý do 3: Hỗ trợ Đồ thị Dị thể (Heterogeneity).

– GraphSAGE dễ dàng tích hợp với wrapper `to_hetero` của thư viện PyG, cho phép xử lý các loại cạnh khác nhau với các bộ trọng số riêng biệt (Relational Message Passing).

7.1.4 Cơ chế GraphSAGE (Graph Sample and aggreGatE)

Trong số các loại GNN, chúng tôi lựa chọn **GraphSAGE** làm bộ mã hóa (Encoder) vì tính chất **Inductive (Quy nạp)** của nó.

- **Vấn đề của GNN cũ:** Thường phải học thuộc lòng toàn bộ đồ thị. Nếu có node mới xuất hiện, phải train lại từ đầu.
- **Giải pháp GraphSAGE:** Thay vì học thuộc lòng, nó học “**cách tổng hợp thông tin**”.
 - Nó học hàm: * “Hãy lấy thông tin của 20 người hàng xóm ngẫu nhiên, tính trung bình cộng, rồi gộp vào bản thân mình”.
 - Nhờ vậy, mô hình có thể xử lý được các node chưa từng gặp trong quá trình huấn luyện, miễn là chúng có kết nối với các node đã biết.
- Lỗi của Encoder là lớp tích chập đồ thị **SAGEConv**. Với mỗi node v , mô hình học cách tổng hợp thông tin từ tập hợp hàng xóm $\mathcal{N}(v)$ của nó.

Công thức cập nhật trạng thái cho lớp l :

$$h_{\mathcal{N}(v)}^{(l)} = \text{MEAN} \left(\{h_u^{(l-1)}, \forall u \in \mathcal{N}(v)\} \right)$$

$$h_v^{(l)} = \sigma \left(\mathbf{W}^{(l)} \cdot \left[h_v^{(l-1)} \parallel h_{\mathcal{N}(v)}^{(l)} \right] \right)$$

Trong đó: * $\parallel$: Phép nối vector (Concatenation). * $\mathbf{W}^{(l)}$: Ma trận trọng số cần học. * σ : Hàm kích hoạt phi tuyến (ReLU).

7.2 Tổng quan dữ liệu huấn luyện

7.2.1 Mô tả dữ liệu

Dữ liệu sau khi trích xuất và thống kê có quy mô như sau: * **Tổng số Node (Thực thể):** ~4.5 triệu node.

* **Phân loại Node (Heterogeneity):** Đồ thị là dạng dị thể (Heterogeneous), bao gồm các loại chính:

* Human (Con người): Chiếm đa số (~70%).

* Organization (Tổ chức/Công ty).

* Work/Film (Tác phẩm/Phim ảnh).

* ... (Các loại khác).

* **Tổng số Edge (Cạnh/Quan hệ):** ~ 9.7 triệu cạnh.

* **Số loại quan hệ (Relation Types):** 4.5 loại (ví dụ: spouse, work_at, acted_in, founded_by...).

7.2.2 Thống kê Phân phối Loại Thực thể (Final Node Type Distribution)

Sau quá trình Tiền xử lý (Data Preprocessing) và Tinh gọn Ngữ nghĩa (Semantic Refactoring), hệ thống hoạt động trên **11 loại thực thể** cốt lõi:

Node Type	Số lượng	Mô tả & Nguồn gộp
Human	3,247,681	Trung tâm kết nối của đồ thị.
Written Work	438,293	Sách, Báo, Kịch bản, Manga.
Film (VisualWork)	315,908	Phim điện ảnh, TV Series, Anime.
Work	193,751	Tác phẩm chung (Tranh, Phần mềm, Radio, Video Game...).

Node Type	Số lượng	Mô tả & Nguồn gộp
Organization	132,170	Công ty, Tổ chức, Câu lạc bộ, Hội nhóm (Gộp Group).
Music	93,942	Bài hát, Album, Tác phẩm âm nhạc.
Position	72,436	Chức vụ, Nghề nghiệp.
Educational Inst.	66,650	Trường học, Viện nghiên cứu.
Award	30,779	Giải thưởng (Oscar, Nobel...).
Event	12,336	Sự kiện lịch sử, Thể thao.
Concept	5,568	Khái niệm, Địa điểm, Nhân vật hư cấu (Gộp Place, Fictional).

Tổng cộng: ~4.6 triệu Nodes. **Nhận xét:** Dữ liệu đã loại bỏ hoàn toàn hiện tượng “Long-tail” (các lớp nhiễu < 0.1%), đảm bảo mật độ dữ liệu (Data Density) đủ dày cho mô hình Deep Learning.

7.2.3 Tại không dùng đồ thị Đồng nhất?

Vì 3 hạn chế chí mạng sau đây (The 3 Fatal Flaws):

– Vấn đề mất mát Ngữ nghĩa (Semantic Loss)

Trong đồ thị đồng nhất, cạnh nối giữa Sơn Tùng M-TP và Taylor Swift (quan hệ thần tượng) sẽ bị đối xử y hệt cạnh nối giữa Sơn Tùng M-TP và Công ty M-TP Ent (quan hệ sở hữu).

→ Hậu quả: Mô hình GNN sẽ học sai lệch. Nó sẽ hiểu lầm rằng mối liên hệ giữa Người-Người và Người-Vật là tương đương nhau, dẫn đến các dự báo phi logic (ví dụ: dự báo Sơn Tùng “kết hôn” với Công ty). Đồ thị dị thể bảo toàn ngữ nghĩa này bằng cách tách biệt các loại cạnh.

– Vấn đề Không gian Đặc trưng (Disjoint Feature Spaces)

- Đây là vấn đề kỹ thuật quan trọng nhất.
 - Human Node: Có thuộc tính birth_year, gender.
 - Film Node: Có thuộc tính release_date, duration, genre.
 - Organization Node: Có thuộc tính founded_date, headquarters.

→ Nếu dùng đồ thị đồng nhất, ta buộc phải gộp tất cả thuộc tính này vào một vector chung khổng lồ (và chứa đầy giá trị 0/Null).

Trong Đồ thị Dị thể, mỗi loại node có không gian vector riêng ($X_{human} \in \mathbb{R}^{d1}, X_{film} \in \mathbb{R}^{d2}$). Mô hình GraphSAGE sẽ học các ma trận chiếu (Projection Matrices) riêng biệt W_{human}, W_{film} để xử lý tối ưu từng loại dữ liệu trước khi tổng hợp.

– Khả năng suy luận qua “Siêu đường dẫn” (Meta-paths)

Đồ thị dị thể cho phép thực hiện các suy luận phức tạp dựa trên mẫu hình kết nối (Meta-path) mà đồ thị đồng nhất không thể nhìn thấy rõ ràng:

– **Co-actor Path:** Human $\xrightarrow{\text{acted_in}}$ Film $\xleftarrow{\text{acted_in}}$ Human. (Hai người cùng đóng một phim → Đồng nghiệp).

– **Colleague Path:** Human $\xrightarrow{\text{work_at}}$ Organization $\xleftarrow{\text{work_at}}$ Human. (Hai người cùng làm một chỗ $\rightarrow$ Đồng nghiệp). Nhờ phân loại rõ ràng node và edge, mô hình có thể phân biệt được trọng số của “Đồng nghiệp phim ảnh” khác với “Đồng nghiệp công sở”.

Human chiếm tới 70-80% dữ liệu? Mất cân bằng thế này mô hình có bị học lệch (Bias) không?” Câu trả lời là **KHÔNG** vì:

– Bản chất của Knowledge Graph (Nature of KG)

Đây là đặc tính tự nhiên của Đồ thị Tri thức xã hội (Social Knowledge Graph). Wikidata là dữ liệu Human-centric (lấy con người làm trung tâm). Sách do người viết, Phim do người đóng, Công ty do người lập. Vì vậy, node Human đóng vai trò là trung tâm kết nối. Việc Human chiếm đa số không phải là lỗi, mà là đặc trưng tô-pô (topological feature) phản ánh đúng thực tế.”

– GraphSAGE không sợ mất cân bằng (Model Robustness)

Khác với bài toán phân loại ảnh (cần số lượng chó/mèo bằng nhau), GraphSAGE học dựa trên Neighbor Sampling (Lấy mẫu hàng xóm). Khi muốn dự đoán về Film, mô hình sẽ lấy mẫu các hàng xóm xung quanh nó (Human, Org...). Việc có nhiều Human trong đồ thị thực ra lại là lợi thế, vì nó cung cấp nguồn thông tin (Context) phong phú để mô hình hiểu rõ hơn về các node loại khác.

7.3 Tổng quan về mô hình

Hệ thống được xây dựng dựa trên kiến trúc **Encoder-Decoder** chuyên biệt cho Đồ thị Tri thức Dị thể (Heterogeneous Knowledge Graph). Mô hình giải quyết bài toán dự đoán liên kết (Link Prediction) thông qua hai giai đoạn chính:

1. **Giai đoạn Mã hóa (Encoding):** Biến đổi các thực thể (Nodes) từ không gian đặc trưng thô sang không gian vector ẩn (Latent Space) giàu ngữ nghĩa.
2. **Giai đoạn Giải mã (Decoding):** Tính toán xác suất tồn tại liên kết giữa hai vector thực thể dựa trên các mẫu tương tác phi tuyến tính.

7.3.1 Thành phần Encoder: Heterogeneous GraphSAGE

Encoder đóng vai trò là “bộ não” trích xuất đặc trưng. Thay vì sử dụng các phương pháp nhúng nông (Shallow Embedding) như TransE hay Node2Vec, mô hình sử dụng **Graph Neural Network (GNN)** để tổng hợp thông tin từ hàng xóm và ngữ cảnh.

Vì đồ thị chứa nhiều loại node (Human, Organization...) và nhiều loại cạnh (spouse, employed_by...), mô hình sử dụng kỹ thuật **Relational Message Passing**: * Mỗi loại cạnh (src, rel, dst) có một bộ trọng số GNN riêng biệt. * Thông tin sau khi truyền qua các loại cạnh khác nhau sẽ được tổng hợp lại (Aggregation = Sum) để tạo ra vector đại diện cuối cùng cho node.

- **Nhiệm vụ:** Biến đổi thông tin thô (Text, Cấu trúc) thành không gian vector ẩn (Latent Space) 64 chiều.
- **Cấu trúc:** 2 lớp SAGEConv + LayerNorm + ReLU.
- **Đầu ra:** Mỗi thực thể (Obama, Microsoft...) được đại diện bởi một vector $z \in \mathbb{R}^{64}$.

Kỹ thuật Feature Engineering Đầu vào Để mô hình không chỉ “học vẹt” các ID vô nghĩa, tôi đã xây dựng vector đặc trưng đầu vào (Input Features) kết hợp 3 yếu tố:

1. **Semantic Features (SBERT):**

- *Định nghĩa:* Sử dụng **Sentence-BERT** để mã hóa văn bản mô tả của thực thể thành vector.
- *Mục đích:* Giúp mô hình **hiểu ngữ nghĩa**. Ví dụ: Vector của “Software Engineer” sẽ nằm gần “Developer” trong không gian số học.

2. **Structural Features (PageRank & Degree):**

- *Degree Centrality:* Đo độ phổ biến cục bộ (số lượng kết nối trực tiếp).
- *PageRank:* Đo tầm quan trọng toàn cục trong cả mạng lưới (Node được liên kết bởi các Node quan trọng khác).
- *Mục đích:* Giúp mô hình nhận diện được các “Influencers” (thực thể trung tâm) trong đồ thị.

3. **Metadata:** Mã hóa năm sinh, giới tính để phục vụ các bộ lọc logic (Logic Constraints).

7.3.2 Thành phần Decoder: Interaction MLP

Đây là điểm cải tiến chính so với các mô hình truyền thống. Thay vì sử dụng tích vô hướng (Dot Product) đơn giản (thường gặp trong Matrix Factorization), mô hình sử dụng một mạng nơ-ron sâu (MLP) để bắt các tương tác phức tạp.

Kiến trúc Decoder: Mixture of Experts (MoE) Đây là phần cải tiến quan trọng nhất trong kiến trúc. Thay vì sử dụng một đầu ra duy nhất để phân loại, hệ thống được thiết kế dựa trên tư tưởng **Mixture of Experts (Hỗn hợp Chuyên gia)**.

Kỹ thuật Feature Engineering Đầu vào Để dự đoán quan hệ r giữa node nguồn u và node đích v , Decoder không chỉ nhìn vào vector gốc mà còn nhìn vào sự tương tác giữa chúng. Đầu vào $\mathbf{x}_{in}$ của Decoder được cấu tạo như sau:

$$\mathbf{x}_{in} = \left[\underbrace{z_u}_{\text{Source}} \parallel \underbrace{z_v}_{\text{Target}} \parallel \underbrace{(z_u \odot z_v)}_{\text{Interaction}} \right]$$

Trong đó:

- z_u, z_v : Vector đặc trưng của hai thực thể.
- $z_u \odot z_v$: Tích Hadamard (Element-wise product). Thành phần này đóng vai trò như một bộ lọc tương đồng, làm nổi bật các chiều kích mà cả hai vector đều có giá trị cao.
- *Tại sao lại dùng nhân Hadamard?*

Để bắt đặc trưng **Tương đồng (Similarity)**. Mạng MLP thông thường rất khó học được tính chất “giống nhau” từ phép nối (concat). Tích Hadamard giúp mô hình nhận diện rõ các đặc điểm chung giữa hai thực thể ngay từ lớp đầu vào.

Cấu trúc Mạng Neural Mạng MLP bao gồm 3 lớp tuyến tính (Linear Layers) kết hợp với Dropout và hàm kích hoạt ReLU, giúp mô hình học được các ranh giới quyết định phi tuyến tính:

$$h_1 = \text{Dropout}(\text{ReLU}(\mathbf{W}_1 \cdot \mathbf{x}_{in} + b_1))$$

$$h_2 = \text{Dropout}(\text{ReLU}(\mathbf{W}_2 \cdot h_1 + b_2))$$

$$\text{Score} = \sigma(\mathbf{W}_3 \cdot h_2 + b_3)$$

Chuẩn hóa Đầu ra (Output Normalization) Tại lớp cuối cùng của Encoder, vector đầu ra z_v được chuẩn hóa L_2 để đưa về mặt cầu đơn vị (Unit Hypersphere):

$$z_v = \frac{h_v^{(L)}}{\|h_v^{(L)}\|_2}$$

Mục đích: Giúp ổn định quá trình huấn luyện và làm cho phép đo độ tương đồng (Cosine Similarity) trở nên hiệu quả hơn.

7.3.3 Giải thích mô hình Decoder

Tại sao cần nhiều Decoder chuyên biệt? Trong các bài toán phân loại ảnh, một tấm ảnh thường chỉ là “Chó” hoặc “Mèo” (loại trừ lẫn nhau), nên ta thường dùng một lớp phân loại chung. Tuy nhiên, trong Đồ thị Tri thức, mỗi quan hệ giữa hai thực thể cực kỳ phức tạp và đa dạng về mặt toán học: * Quan hệ **spouse** (Vợ chồng): Có tính đối xứng ($A \leftrightarrow B$ cưới A). * Quan hệ **parent_of** (Cha mẹ): Có tính thứ bậc, một chiều. * Quan hệ **work_at** (Làm việc): Có tính liên kết giữa hai loại thực thể khác nhau (Người - Tổ chức).

Vấn đề: Nếu ép một mạng nơ-ron duy nhất phải học tất cả các quy luật vật lý/xã hội trái ngược này, mô hình sẽ bị “rối loạn” và hội tụ kém (Underfitting).

Giải pháp: Chúng tôi tạo ra các **Decoder Chuyên gia**. Mỗi Decoder là một mạng MLP riêng biệt, chỉ chuyên tâm học một loại quan hệ duy nhất. * *Expert A*: Chuyên học về quan hệ gia đình. * *Expert B*: Chuyên học về quan hệ công việc.

Tại sao dùng Sigmoid thay vì Softmax? (Multi-label Nature) Một câu hỏi thường gặp là tại sao không dùng hàm Softmax để chọn ra quan hệ có xác suất cao nhất?

Lý do là bản chất **Đa nhãn (Multi-relational)** của thế giới thực. Giữa hai thực thể A và B có thể tồn tại song song nhiều mối quan hệ: * A là **đồng nghiệp** của B. * A cũng là **bạn bè** của B. * A cũng là **cố vấn** cho B.

Nếu dùng Softmax, tổng xác suất phải bằng 1, nghĩa là nếu xác suất **đồng nghiệp** tăng lên thì xác suất **bạn bè** buộc phải giảm đi. Điều này sai thực tế.

Chúng tôi sử dụng hàm **Sigmoid** độc lập cho từng Decoder. Điều này cho phép mô hình khẳng định: “*Xác suất họ là đồng nghiệp là 90%, VÀ xác suất họ là bạn bè là 85%*”. Các xác suất này không triệt tiêu nhau.

Cơ chế Shared Decoder (Hỗ trợ Zero-shot):

- Thay vì tạo Decoder cho từng cặp loại node (ví dụ: **Human-WorkAt-Org**), tôi gộp Decoder theo **Tên Quan Hệ (work_at)**.
- **Lợi ích:**
 - Giảm số lượng tham số, tránh Overfitting.

- **Zero-shot Learning:** Mô hình có thể dự đoán quan hệ giữa các loại thực thể chưa từng gặp trong tập train (ví dụ: học “Thành viên” từ Người-Nhóm, áp dụng sang Công ty-Hiệp hội).

Lợi ích của Kiến trúc “Chuyên gia Dựa trên Tên Quan hệ” Thay vì gán cứng mỗi cặp loại node (ví dụ: Human-Org) với một bộ xử lý, chúng tôi gán bộ xử lý theo

Tên quan hệ (Relation Name).

Ví dụ: Decoder `__member_of__` chịu trách nhiệm cho khái niệm “Thành viên”.

- **Khả năng Zero-shot (Vay mượn tri thức):** Khi Decoder này đã học được khái niệm “Thành viên” từ dữ liệu `Human-Group` (Người là thành viên Nhóm), nó có thể áp dụng ngay kiến thức đó cho cặp `Organization-Consortium` (Tổ chức là thành viên Hiệp hội) mà không cần phải học lại từ đầu.
- **Tránh bùng nổ tham số:** Thay vì tạo ra hàng nghìn decoder cho mọi cặp tổ hợp loại node (`Human-Human`, `Human-Org`, `Org-Group`...), chúng tôi chỉ cần số lượng decoder bằng đúng số lượng loại quan hệ (khoảng vài chục). Điều này giúp mô hình nhẹ, nhanh và ít bị Overfitting trên các loại cạnh hiếm gặp.

7.3.4 Quy trình huấn luyện và Tối ưu hóa

– Để đảm bảo mô hình có khả năng tổng quát hóa (Generalization) tốt trên các dữ liệu chưa từng thấy và giải quyết các thách thức đặc thù của Đồ thị Dị thể quy mô lớn, chúng tôi áp dụng chiến lược chia tách dữ liệu nâng cao Inductive Disjoint Split thông qua module `RandomLinkSplit` của `PyTorch Geometric`.

– Cấu hình chia tách được thiết lập như sau:

Tỷ lệ phân chia: Train (98%) - Validation (1%) - Test (1%).

Cơ chế: Disjoint Edge Splitting (Tách rời cạnh truyền tin và cạnh giám sát).

Dưới đây là 3 kỹ thuật cốt lõi được áp dụng trong quá trình này:

Kỹ thuật “Disjoint Training” (Tách rời Ngữ cảnh và Nhân) – Khác với các phương pháp truyền thống thường sử dụng chung một tập cạnh cho cả hai nhiệm vụ truyền tin (Message Passing) và tính toán lỗi (Loss Calculation), chúng tôi thiết lập tham số `disjoint_train_ratio=0.3`.

– Cơ chế: **Tập huấn luyện** (Train Set) được chia nhỏ thành hai phần riêng biệt:

Message Passing Edges (70%): Chỉ được sử dụng để các node trao đổi thông tin và cập nhật vector đặc trưng. Mô hình không thực hiện dự báo trên các cạnh này.

Supervision Edges (30%): Các cạnh này bị ẩn đi khỏi cấu trúc đồ thị (Message Passing Graph). Mô hình buộc phải sử dụng thông tin từ 70% cạnh còn lại để suy luận ra sự tồn tại của 30% cạnh này.

Mục đích: Kỹ thuật này ép buộc mô hình phải học theo cơ chế Quy nạp (Inductive Learning) – tức là học quy luật kết nối thay vì học thuộc lòng (Transductive/Memorization). Điều này mô phỏng chính xác kịch bản thực tế khi mô hình phải dự báo mối quan hệ cho các thực thể mới.

Cơ chế Chống Rò rỉ Dữ liệu (Leakage Prevention via Reverse Edges) – Trong Đồ thị xã hội, các mối quan hệ thường có tính chất hai chiều hoặc tương hỗ (Ví dụ: Nếu $A \xrightarrow{work_at} B$ tồn tại, thì trong dữ liệu cũng tồn tại cạnh ngược $B \xrightarrow{employ} A$). Nếu không xử lý, GNN có thể “gian lận” bằng cách nhìn thấy cạnh ngược và suy ra ngay lập tức cạnh xuôi tương ứng mà không cần học đặc trưng ngữ nghĩa.

– **Giải pháp:** Chúng tôi khai báo tham số **rev_edge_types**. Khi một cạnh được chọn làm nhãn dự báo (Label), hệ thống sẽ tự động loại bỏ cạnh ngược tương ứng của nó khỏi đồ thị truyền tin.

– **Kết quả:** Đảm bảo tính trung thực tuyệt đối của quá trình đánh giá (Evaluation Integrity).

Tối ưu hóa Tài nguyên với “On-the-fly Negative Sampling” – Với đồ thị 9.7 triệu cạnh dương, việc sinh trước (Pre-generate) các cạnh âm (Negative Edges) theo tỷ lệ 1:1 sẽ tạo ra thêm 9.7 triệu cạnh rác, gây lãng phí bộ nhớ RAM nghiêm trọng.

– **Giải pháp:** Chúng tôi thiết lập **add_negative_train_samples=False** và chuyển giao nhiệm vụ này cho LinkNeighborLoader.

– **Hiệu quả:** Các cạnh âm được sinh ngẫu nhiên theo thời gian thực (Real-time) ngay trong quá trình huấn luyện từng Batch. Điều này không chỉ tiết kiệm RAM mà còn giúp mô hình được tiếp xúc với các mẫu âm đa dạng hơn qua từng Epoch, tăng cường độ bền vững (Robustness).

Chiến lược huấn luyện mô hình (TRAINING PIPELINE) Quy trình huấn luyện được chia làm 3 giai đoạn (Phases) chiến lược nhằm tối ưu hóa bộ mã hóa (Encoder) và bộ giải mã (Decoder) trên đồ thị dị thể.

Giai đoạn 1: Huấn luyện sâu liên kết xã hội (Human-Human)

- Giai đoạn này tập trung vào việc học các đặc trưng cốt lõi từ cấu trúc mạng lưới xã hội trực tiếp giữa người dùng.
- Mục tiêu: Xây dựng vector nhúng (Embeddings) nền tảng cho thực thể “Human”.
- Thông số:
 - Đối tượng: Các loại cạnh liên kết xã hội $Human \leftrightarrow Human$.
 - Số lượng: 10 Epochs.
 - Cơ chế: Huấn luyện sâu (Deep training) để cập nhật toàn bộ trọng số của các lớp SAGEConv.

Giai đoạn 2: Huấn luyện nông liên kết hệ thống (Human-Hubs)

Sau khi có nền tảng về quan hệ xã hội, mô hình được tinh chỉnh để nhận diện thêm các liên kết tới các điểm tập trung dữ liệu (Hubs) như sở thích, vị trí hoặc tổ chức.


- Mục tiêu: Giúp mô hình thích nghi với các loại cạnh mới mà không làm mất đi thông tin xã hội đã học.
- Thông số:
 - Đối tượng: Các loại cạnh liên kết $Human \leftrightarrow Hubs$.
 - Số lượng: 2 Epochs (Huấn luyện nông).

- Tốc độ học (Learning Rate): $\eta = 0.001$.
- Ý nghĩa: Tốc độ học thấp giúp mô hình cập nhật trọng số một cách ổn định, tránh hiện tượng nhiễu dữ liệu.

Giai đoạn 3: Huấn luyện riêng Decoder (All Edges)

Đây là bước tối ưu hóa cuối cùng, tập trung hoàn toàn vào khả năng dự đoán xác suất liên kết của bộ giải mã.

- Mục tiêu: Hội tụ khả năng dự đoán trên toàn bộ các loại cạnh có trong đồ thị.
- Thông số:
 - Đối tượng: Tất cả các loại cạnh (All Edges).
 - Số lượng: 20 Epochs.
 - Tốc độ học (Learning Rate): $\eta = 0.1$.
- Đặc điểm: Chỉ tập trung huấn luyện phần Decoder, các trọng số của Encoder thường được giữ cố định để bảo toàn các vector nhúng chất lượng cao đã học được từ GD1 và GD2.



7.3.5 Chiến lược suy luận & ứng dụng

Quy trình Lọc 2 Lớp (Two-Layer Filtering) Để đảm bảo kết quả đầu ra chính xác và hợp lý, hệ thống áp dụng: 1. **Lớp 1: Semantic Filter (Tại Model):** Chặn các quan hệ phi logic về mặt sinh học (Ví dụ: `Organization` không thể có `spouse`). 2. **Lớp 2: Business Filter (Tại Service):** Kiểm tra các ràng buộc xã hội (Ví dụ: Không gợi ý kết hôn giữa anh em ruột - Taboo check, kiểm tra khoảng cách tuổi tác).

Ứng dụng Thực tế (Real-world Impact) Hệ thống có thể được triển khai cho các bài toán: 1. **Hệ thống Gợi ý (Recommender Systems):** Gợi ý kết bạn, gợi ý sản phẩm dựa trên mối quan hệ bắc cầu. 2. **Hoàn thiện Tri thức (Knowledge Completion):** Tự động phát hiện và điền khuyết các thông tin còn thiếu trong cơ sở dữ liệu lớn. 3. **Phát hiện Gian lận (Fraud Detection):** Tìm ra các mối liên hệ ẩn giữa các tài khoản trong mạng lưới tội phạm tài chính.

KẾT QUẢ THỰC NGHIỆM (KEY METRICS)

- **AUC (Area Under Curve):** Đạt **0.76** (Thể hiện khả năng phân loại tốt giữa liên kết thật và giả).
- **AP (Average Precision):** Đạt **0.82** (Độ chính xác trung bình).

Ý NGHĨA THÔNG SỐ ĐÁNH GIÁ:

1. ROC-AUC (Khả năng phân loại tổng quát)

- Tên đầy đủ: Area Under the Receiver Operating Characteristic Curve.
- Ý nghĩa: Đây là khả năng “Xếp hạng đúng sai” của mô hình trên toàn bộ dữ liệu.
- Câu hỏi nó trả lời: “Nếu tôi nhắm mắt chọn bừa 1 cặp CÓ liên kết (Positive) và 1 cặp KHÔNG liên kết (Negative), xác suất mô hình chấm điểm cho cặp CÓ cao hơn cặp KHÔNG là bao nhiêu?” Thang điểm:
 - 0.5: Đoán mò (như tung đồng xu sắp ngửa).
 - 0.7 - 0.8 :. Đây là mức Khá Tốt cho dữ liệu xã hội nhiều.
 - 0.8 - 1.0: Mô hình xuất sắc.
 - Điểm yếu: AUC đánh giá công bằng cả những liên kết rất khó và rất dễ. Nó quan tâm đến “bức tranh toàn cảnh” hơn là chất lượng của top đầu.

2. AP - Average Precision (Độ chính xác trung bình)

- Tên đầy đủ: Average Precision (Diện tích dưới đường cong Precision-Recall).
- Ý nghĩa: Đây là độ “tín nhiệm” của mô hình, đặc biệt tập trung vào lớp Positive (Liên kết thật). Nó phạt rất nặng nếu mô hình tự tin dự đoán là “Có” mà thực tế lại là “Không”. Câu hỏi nó trả lời: “Trong số những cặp mà mô hình tự tin nhất và gợi ý lên đầu trang, có bao nhiêu phần trăm là đúng thật?” .

7.4 Ứng dụng dự đoán liên kết thực nghiệm

```
[1]: from core.ai import LinkPredictionModel, Predictor
from application import AIService
import torch
```

Ta sẽ khởi tạo mô hình embeddings là bộ vector do encoder đã được tính trước sau khi training để dự đoán nhanh hơn.

```
[2]: import pickle
embeddings = torch.load('data_output/predicting/embeddings.pt')
with open('data_output/predicting/metadata.pkl', 'rb') as f:
    metadata = pickle.load(f)
state_dict = torch.load('data_output/models/model.pt', weights_only=False)
```

```
[4]: model = LinkPredictionModel(256, 128, metadata = metadata)
model.load_state_dict(state_dict)
```

Ta phải khởi tạo predictor trước khi dự đoán

```
[ ]: predictor = Predictor(model, embeddings)
```

```
[11]: ai_service = AIService(model, search_engine, predictor)
```

AI: Đang khởi tạo bộ máy dự đoán!

AI: Sẵn sàng!

Sau khi mô hình đạt được độ chính xác kỳ vọng, hệ thống triển khai các dịch vụ dự báo theo 4 kịch bản thực tế:

7.4.1 Xác suất hình thành quan hệ (A và B)?

Hệ thống tính toán điểm số tương đồng giữa hai vector nhúng z_A và z_B . Kết quả được chuyển đổi qua hàm Sigmoid để đưa ra tỉ lệ phần trăm kết nối.

$$\hat{y}_{AB} = f_{MLP}(z_A, z_B) \in [0, 1]$$

```
[8]: ai_service.predict_link_score("Sơn Tùng M-TP", "Snoop Dogg", )
```

Đang tìm: 'Sơn Tùng M-TP'...

-> Đã chọn: Sơn Tung M-TP (ID: 1761982)

Đang tìm: 'Snoop Dogg'...

-> Đã chọn: Snoop Dogg (ID: 3303767)

PHÂN TÍCH QUAN HỆ: Sơn Tùng M-TP human #1168453 vs Snoop Dogg human #2236787

DỰ ĐOÁN CHÍNH: [COLLABORATE_WITH] (Độ tin cậy: 72.42%)

collaborate_with	: 0.7242	(cao)
influenced_by	: 0.6710	(có thể)
advisor_of	: 0.545	(có thể)
sibling	: 0.4900	(thấp)
spouse	: 0.2043	(rất thấp)

-
- Sơn Tùng MT-P đã từng hợp tác với Snoop Dogg trong sản phẩm âm nhạc Hãy Trao Cho Anh.
→ Điểm khá cao

7.4.2 Gợi ý thực thể tiềm năng cho A?

Sử dụng mô hình để quét không gian nhúng của các nút lân cận. Những thực thể X có giá trị $\hat{y}_{AX}$ cao nhất sẽ được liệt kê là những đối tượng có khả năng cao nhất hình thành quan hệ với A trong tương lai.

```
[20]: ai_service.recommendations("Hồ Chí Minh", top_k=10)
```

Đang tìm: 'Hồ Chí Minh'...

-> Đã chọn: Hồ Chí Minh (ID: 1716593)

GỢI Ý (GLOBAL) CHO HỒ CHÍ MINH

#01 Đảng Cộng sản VN	- [founder_of] - 0.8255
#02 Quoc Hoc - Hue High School for the Gifted	- [educated_at] - 0.8221
#03 Communist University of the Toilers of the East	- [educated_at] - 0.8014
#04 Hoàng Thị Loan	- [mother] - 0.7602
#05 Nguyễn Sinh Sắc	- [father] - 0.7208
#06 Order of Lenin	- [award_received] -
0.7031	
#07 Star of the Republic of Indonesia	- [award_received] -
0.6992	
#08 Grand Cross of the Order of Polonia Restituta	- [award_received] -
0.6706	
#09 Gold Star Order	- [award_received] -
0.6531	
#10 Pablo Picasso	- [collaborate_with] -
0.6221	

Sự thống trị của các Node trung tâm (Hub Dominance) - [Top 1-3]

- Hiện tượng: Đảng CS VN (0.82) và Các trường học đứng đầu, cao hơn cả Cha Mẹ.
- Lý do: Trong đồ thị Knowledge Graph, các node tổ chức (Org) như “Đảng” hay “Trường học” là các Hub Nodes (Node trung tâm) có bậc (degree) rất lớn.

GNN (GraphSAGE) hoạt động theo cơ chế tổng hợp thông tin từ lân cận (Neighborhood Aggregation).

Dòng thông tin từ các Hub lớn này “chảy” về node trung tâm (Bác Hồ) mạnh mẽ hơn và mang nhiều đặc trưng định danh (Identity features) hơn so với các node lá (Leaf nodes) như cá nhân cha mẹ.

Kết luận: Model đánh giá “Sự nghiệp” định nghĩa con người Bác rõ nét hơn “Gia phả”.

Kết nối mạnh nhưng cục bộ (Local Strong Ties) - [Top 4-5]

- Hiện tượng: Hoàng Thị Loan và Nguyễn Sinh Sắc có điểm cao (0.76 - 0.72) nhưng thấp hơn sự nghiệp.
- Lý do: Đây là các kết nối 1-hop trực tiếp cực mạnh. Tuy nhiên, vector của “Nguyễn Sinh Sắc” trong không gian nhúng có thể khá biệt lập (ít kết nối với các node quốc tế khác). Do đó, điểm số cosine similarity bị kéo xuống nhẹ so với các node có tính kết nối toàn cầu như “Quốc Học Huế”.

Hiệu ứng “Tương đương cấu trúc” (Structural Equivalence) - [Top 6-9]

- Hiện tượng: Các huân chương (Lenin, Indonesia, Sao Vàng) xuất hiện liên tiếp nhau với điểm số sần sần (0.65 - 0.70).
- Lý do: GNN học được rằng các node này đóng vai trò giống hệt nhau trong đồ thị (đều là node loại Award nối vào node Politician).

Khi Model thấy Bác nhận Huân chương Lenin, nó sẽ tự động kéo vector Bác lại gần cụm “Các giải thưởng Xã hội chủ nghĩa”.

Đây là lý do Huân chương Sao Vàng (Gold Star) vẫn hiện ra dù Bác từ chối: Về mặt toán học, vector của Bác và vector của giải thưởng này nằm rất gần nhau.

Suy diễn ngữ cảnh (Contextual Inference) - [Top 10]

- Hiện tượng: Pablo Picasso (0.62).
- Lý do: Đây là minh chứng cho việc Model đã học được Context (Bối cảnh).

Cả hai không có cạnh trực tiếp `connected_to`.

Nhưng họ chia sẻ chung một tập hợp các node lân cận ẩn: Paris, French Communist Party, Left-wing Ideology.

Encoder đã nén thông tin “Hoạt động tại Pháp những năm 1920” vào vector của cả hai, khiến điểm tương đồng vọt lên mức đáng kể (0.62) so với người lạ (thường < 0.1).

7.4.3 Dự báo loại quan hệ (Multi-relational Link Prediction)

Thay vì chỉ dự đoán sự tồn tại của cạnh, mô hình Decoder sẽ phân loại cạnh đó vào một trong 22 nhãn quan hệ đã định nghĩa (ví dụ: *educated_at*, *employer*, *spouse*).

$$Relation(A, B) = (f_{MLP}(\mathbf{z}_A, \mathbf{z}_B))$$

```
[6]: ai_service.recommendations_relationship('Hồ Chí Minh', 'educated_at', top_k=5)
```

Đang tìm: 'Hồ Chí Minh'...

-> Đã chọn: Ho Chi Minh (ID: 2585277)

Tìm Top 5 'educated_at' cho Hồ Chí Minh...

GỢI Ý CHO EDUCATED_AT

#01 Quoc Hoc - Hue High School for the Gifted | 0.8221

#02 Communist University of the Toilers of the East | 0.8014

#03 International Lenin School | 0.7245

#04 Sorbonne University | 0.7042

#05 Yale University | 0.6402

Độ chính xác lịch sử (Top 1-3):

- #01 & #02 (True Positives): Mô hình đã bắt chính xác 2 mốc quan trọng nhất: Quốc Học Huế (thời niên thiếu tại Việt Nam) và Đại học Phương Đông (thời kỳ hoạt động tại Liên Xô). Điểm số > 0.8 cho thấy liên kết này cực kỳ mạnh trong đồ thị.
- #03 (International Lenin School): Đây cũng là một dự đoán chính xác (Bác từng học tập và làm việc tại Viện Lênin). Việc GNN nhóm các trường ở Moscow lại gần nhau cho thấy nó đã học được Context địa lý/chính trị.

Sự suy diễn logic (Top 4 - False Positive “hợp lý”): * #04 Sorbonne University: Bác Hồ chưa từng chính thức học lấy bằng tại Sorbonne. Tuy nhiên, thời gian Bác ở Paris, tham gia Đảng xã hội Pháp và nghiên cứu tại các thư viện lớn đã khiến Vector của Bác bị kéo lại gần cụm “Trí thức Paris”. Đây là một “ảo giác thông minh” của AI (đoán sai sự thật nhưng đúng về ngữ cảnh).

Nhiều (Top 5 - Noise): * #05 Yale University: Đây là nhiễu. Có thể do Bác từng đến Mỹ (Boston/New York) hoặc do Yale là một node trung tâm (Hub node) trong mạng lưới giáo dục toàn cầu nên nó thường xuất hiện trong Top 5 của nhiều lãnh đạo thế giới. Tuy nhiên, điểm số đã tụt xuống 0.68, cho thấy Model cũng “bán tín bán nghi” về kết quả này.

7.4.4 Dự đoán quan hệ đặc thù: Vợ chồng (Spouse Prediction)?

Đây là bài toán dự đoán có ràng buộc. Ngoài việc dựa vào điểm số từ GNN, hệ thống kết hợp thêm các **Ràng buộc logic (Hard Constraints)**: * Thực thể phải có loại đỉnh là **human**. * Khoảng cách năm sinh (birthYear) nằm trong ngưỡng logic xã hội. * Không tồn tại các quan hệ huyết thống trực tiếp đối nghịch trong đồ thị tri thức.

```
[18]: ai_service.predict_spouse_with_constraints('Trần Thành', top_k= 5)
```

Đang tìm: 'Trần thành'...

-> Đã chọn: Trần Thành (ID: 383064)

GỢI Ý VỢ CHỒNG CHO HUMAN #278455 | THÔNG TIN: 1987/male

ỨNG VIÊN VỢ/CHỒNG CHO Trần Thành

Hari Won (1985/female) - Score: 0.7658

Mai Hồ (1987/female) - Score: 0.6138

Tuấn Trần (1992/male) - Score: 0.5858

Thu Trang (1984/female) - Score: 0.5687

Việt Hương (1976/female) - Score: 0.5058

Độ chính xác tuyệt đối (Top 1):

- Hari Won (0.7658): Model đã xác định chính xác người vợ hiện tại với điểm số vượt trội (cách biệt > 0.15 so với người thứ 2). Điều này cho thấy liên kết spouse trong đồ thị rất mạnh và vector của cả hai đã được kéo sát lại nhau.

Nhảy bèn với quá khứ (Top 2):

- Mai Hồ (0.6138): Việc người yêu cũ đứng ngay vị trí số 2 là một tín hiệu cực tốt về mặt “Học biểu diễn” (Representation Learning). Model đã nắm bắt được tín hiệu “Quan hệ lãng mạn” (Romantic context) từ dữ liệu lịch sử, dù hiện tại họ không còn bên nhau.

Hiệu ứng “Hội nhóm” (The Clique Effect):

- Tuấn Trần (0.5858): Dù là nam, nhưng việc Tuấn Trần lọt vào danh sách gợi ý “Bạn đời” cho thấy Model đang nhìn thấy cấu trúc cộng đồng. Vector của Tuấn Trần quá gần Trần Thành do tần suất xuất hiện chung dày đặc, khiến AI coi đây là một người “cực kỳ thân thiết” (Intimate tie).

7.4.5 Cơ chế Shared-Decoder?

Đây là bài toán đánh giá tính tổng quát của mô hình. Ngoài việc dựa trên các loại cạnh có sẵn, mô hình sẽ dự đoán các loại cạnh chưa từng xuất hiện dựa trên cơ chế shared-decoder*: * Ta có loại cạnh **human-member_of-organization**. * Ta sẽ đi dự đoán loại cạnh **organization-member_of-organization**. Một loại cạnh hoàn toàn không xuất hiện trong dữ liệu huấn luyện.

```
[5]: ai_service.recommendations_shared('Ho Chi Minh City University of Science',  
    ↪ 'member_of', top_k=5)
```

Đang tìm: 'Ho Chi Minh City University of Science'...

-> Đã chọn: VNU-HCM University of Science (ID: 3215700)

PHÂN TÍCH (SHARED DECODER)

Logic: Quét quan hệ 'member_of'

KẾT QUẢ DỰ ĐOÁN: [MEMBER_OF]

ĐHQG TP.HCM (VNU-HCM)	: 0.6452	(Cố thể)
Bộ Giáo dục & Đào tạo	: 0.4120	(Thấp)
ĐHQG Hà Nội (VNU-HN)	: 0.1560	(Rất thấp)
Tập đoàn FPT	: 0.0230	(Rất thấp)

Kết quả này chứng minh tính khả thi của việc Transfer Learning (Chuyển giao tri thức): Model đã học khái niệm “Thành viên” từ con người (Human) và áp dụng thành công sang cho tổ chức (Organization). **Khả năng phân bậc quản lý (Hierarchy Detection):**

- VNU-HCM (0.6452) > Bộ Giáo dục (0.4120): Model đã phân biệt được sự khác nhau giữa “Đơn vị chủ quản trực tiếp” (ĐHQG) và “Cơ quan quản lý nhà nước” (Bộ).
- Trong đồ thị, KHTN kết nối chặt chẽ với các trường thành viên khác của ĐHQG, tạo nên một cụm (Cluster) mạnh, giúp điểm số của ĐHQG cao hơn hẳn so với Bộ.

Độ nhạy về ngữ nghĩa (Semantic Sensitivity):

- VNU-HN (0.1560): Mặc dù cùng có tên là “ĐHQG” (National University) và cùng tính chất học thuật, nhưng Model không bị nhầm lẫn. Nó nhận ra sự khác biệt về Địa lý (Hà Nội vs TP.HCM) và Mạng lưới kết nối (KHTN không có giảng viên hay sinh viên chung với VNU-HN).

Phân loại lĩnh vực (Domain Separation):

- FPT (0.0230): Điểm số tiệm cận 0. Model đã tách biệt hoàn toàn hai không gian vector: Khối Học thuật (Academic) và Khối Doanh nghiệp (Corporate). Dù FPT cũng làm về công nghệ/giáo dục, nhưng cấu trúc đồ thị của nó hoàn toàn khác biệt so với KHTN.

Kết luận: Shared Decoder hoạt động hiệu quả. Dù điểm số (0.64) chưa cao tuyệt đối như quan hệ vợ chồng (do dữ liệu tổ chức thường thưa thớt hơn dữ liệu xã hội), nhưng thứ hạng (Ranking) là hoàn toàn chính xác.

8 KẾT LUẬN

Đồ án “**Social Link Analysis and Prediction**” đã hoàn thành mục tiêu xây dựng một hệ thống toàn diện để khai phá và dự báo các mối quan hệ xã hội trên nền tảng Đồ thị Tri thức (Knowledge Graph), kết hợp giữa lý thuyết đồ thị truyền thống và các kỹ thuật Deep Learning hiện đại. Các kết quả đạt được có thể tóm tắt qua ba trụ cột chính:

1. Về Xây dựng và Phân tích Dữ liệu (Data Engineering & Network Analysis):

- Kiến tạo Đồ thị Dị thể quy mô lớn:** Đồ án đã thiết lập thành công quy trình ETL (Extract - Transform - Load) phức tạp để xử lý dữ liệu từ Wikidata, xây dựng một đồ thị dị thể (Heterogeneous Graph) với quy mô khoảng **4.6 triệu đỉnh** (Nodes) và **9.7 triệu cạnh** (Edges). Cấu trúc dữ liệu được chuẩn hóa với 11 loại thực thể cốt lõi, trong đó “Human” đóng vai trò trung tâm kết nối.

- **Kiểm chứng giả thuyết khoa học:** Thông qua thực nghiệm trên 100,000 cặp mẫu ngẫu nhiên, đồ án đã chứng minh tính đúng đắn của giả thuyết “**Sáu bậc phân cách**” (Six Degrees of Separation) trên dữ liệu thực tế, khẳng định mạng lưới tri thức Wikidata mang đặc tính “Thế giới nhỏ” (Small-world network) với khả năng kết nối chặt chẽ.
- **Phân tích topo mạng lưới:** Các phân tích về phân phối bậc (Degree Distribution) và chỉ số Gamma () cho thấy mạng lưới đang trong giai đoạn chuyển dịch, tiệm cận cấu trúc mạng ngẫu nhiên nhưng vẫn tồn tại các “Hubs” (siêu nút) nắm giữ quyền lực kết nối lớn.

2. Về Mô hình Trí tuệ Nhân tạo (AI Modeling):

- **Kiến trúc Neuro-Symbolic tiên tiến:** Đồ án đã áp dụng thành công hướng tiếp cận lai giữa khả năng học biểu diễn của **Neural Networks** và tư duy logic của **Symbolic AI**.
- **Sức mạnh của GraphSAGE:** Việc lựa chọn GraphSAGE làm Encoder đã giải quyết triệt để bài toán **Inductive Learning** (Học quy nạp), cho phép mô hình dự đoán được trên các thực thể mới mà không cần huấn luyện lại toàn bộ đồ thị, đảm bảo khả năng mở rộng (Scalability).
- **Đột phá trong thiết kế Decoder:** Kiến trúc **Interaction MLP** kết hợp với tích Hadamard và cơ chế **Shared Decoder** (Chia sẻ trọng số theo tên quan hệ) là điểm sáng kỹ thuật. Giải pháp này không chỉ giúp mô hình xử lý tốt bản chất đa quan hệ (Multi-relational) mà còn mở ra khả năng **Zero-shot Learning** – dự đoán được các loại liên kết chưa từng xuất hiện trong tập huấn luyện.

3. Về Ứng dụng Thực tiễn:

- Hệ thống đã chứng minh khả năng hoạt động hiệu quả qua các bài toán thực tế như: Dự báo xác suất quan hệ (Link Prediction), Gợi ý kết nối (Recommendation System) và Dự đoán quan hệ đặc thù có ràng buộc (như dự đoán vợ/chồng với logic về tuổi tác và huyết thống).
- Cơ chế **Lọc 2 lớp** (Semantic Filter và Business Filter) đảm bảo các dự đoán đưa ra không chỉ chính xác về mặt toán học (High Score) mà còn hợp lý về mặt ngữ nghĩa và xã hội.

Tóm lại, đồ án không chỉ dừng lại ở mức độ lý thuyết mà đã hiện thực hóa thành một công cụ phân tích mạnh mẽ, đóng góp vào việc giải quyết bài toán “Vùng tối tri thức” và hoàn thiện cơ sở dữ liệu tri thức mở.

9 HƯỚNG PHÁT TRIỂN VÀ CẢI TIẾN MÔ HÌNH

Dựa trên những kết quả sơ bộ, đồ án định hướng mở rộng nghiên cứu sang các kiến trúc Graph Neural Network (GNN) tiên tiến hơn nhằm giải quyết triệt để tính chất dị thể (heterogeneity) và quy mô lớn của đồ thị tri thức Wikidata.

– Từ GCN/GraphSAGE sang Graph Attention Networks (GAT)

- **Hạn chế hiện tại:** Các mô hình cơ bản thường coi vai trò của mọi nút lân cận là như nhau (GCN) hoặc lấy mẫu ngẫu nhiên (GraphSAGE), dẫn đến việc bỏ lỡ các mối quan hệ xã hội mang tính chất quyết định.
- **Giải pháp GAT:** Tích hợp cơ chế **Self-Attention** (tự sự chú ý).
 - Mô hình sẽ học được *hệ số alpha* (α_{ij}) thể hiện mức độ quan trọng của nút hàng xóm j đối với nút i .

- **Trong bối cảnh bài toán:** Ví dụ, khi dự đoán mối quan hệ chính trị, GAT sẽ tự động học để “chú ý” nhiều hơn đến các kết nối là *đồng phái* hoặc *đồng nghiệp*, thay vì các kết nối *gia đình*.
- **Heterogeneous Graph Transformer (HGT)**
 - **Bối cảnh:** Đồ thị hiện tại là đồ thị dị thể với nhiều loại nút (*Người, Phim, Trường học*) và nhiều loại cạnh. Việc áp dụng các mô hình đồng nhất (Homogeneous GNN) buộc phải gộp chung các loại này, làm mất mát thông tin ngữ nghĩa.
 - **Giải pháp HGT:** Đây là kiến trúc State-of-the-Art cho đồ thị dị thể.
 - **Meta-Relation Aware:** HGT không dùng chung tham số mà có bộ tham số riêng cho từng loại quan hệ và loại nút.
 - **Cấu trúc Transformer:** Áp dụng cơ chế Multi-head Attention để mô hình hóa sự phụ thuộc phức tạp giữa các thực thể khác loại mà không cần thiết kế thủ công các siêu đường dẫn (meta-paths).
- **GatedHeteroSAGE**
 - **Ý tưởng:** Là sự cải tiến của GraphSAGE nhằm tối ưu hóa cho đồ thị dị thể thông qua cơ chế Cổng (Gating Mechanism) tương tự như mạng Neural hồi quy (LSTM/GRU).
 - **Cơ chế hoạt động:**
 - Khi tổng hợp thông tin từ các láng giềng khác loại, mô hình sử dụng một **cổng lọc (Gated update)** để quyết định bao nhiêu thông tin cũ nên được giữ lại và bao nhiêu thông tin mới từ hàng xóm nên được dung nạp.
 - **Lợi ích:** Giúp mô hình tránh ngộ độc thông tin (over-smoothing) khi đồ thị quá dày đặc, đồng thời học tốt hơn các biểu diễn đặc trưng cho những nút hiếm (long-tail nodes) trong mạng xã hội.

10 8. TÀI LIỆU THAM KHẢO

1. **Milgram, S. (1967).** “The Small World Problem”. *Psychology Today*, 2, 60-67.
 - *Nghiên cứu gốc đặt nền móng cho khái niệm “Sáu bậc phân cách”.*
2. **Watts, D. J., & Strogatz, S. H. (1998).** “Collective dynamics of ‘small-world’ networks”. *Nature*, 393(6684), 440–442.
 - *Giới thiệu mô hình toán học cho mạng lưới thế giới nhỏ (Watts-Strogatz model).*
3. **Barabási, A. L. (2016).** *Network Science*. Cambridge University Press.
 - *Sách giáo khoa nền tảng về khoa học mạng lưới, bao gồm các khái niệm về bậc (degree), đường đi (path length) và clustering coefficient.*
4. **Leskovec, J., Rajaraman, A., & Ullman, J. D. (2020).** *Mining of Massive Datasets*. Cambridge University Press.
 - *Tài liệu tham khảo về các thuật toán xử lý đồ thị lớn (Big Data).*
5. **Wikidata. (2024).** *Wikidata Query Service & Dumps*. Retrieved from <https://www.wikidata.org/>
 - *Nguồn dữ liệu xây dựng đồ thị tri thức.*
6. **Bài giảng môn Python cho Khoa học dữ liệu** của ThS. Hà Văn Thảo.